Tellende prosjekt i ISTx1003

H2026

Stefanie Muff, Institutt for matematiske fag, NTNU

Tellende prosjekt i ISTx1003 - 2026

I prosjektdelen av ISTx1003 Statistikk, Statistisk læring og data science, har vi fokus på tre hovedtemaer: regresjon, klassifikasjon og klyngeanalyse.

- Prosjektoppgaven teller 30% av karakteren i emnet.
- Det må være 3-6 studenter på hver gruppe, og alle studenter må være oppmeldt i den samme emnekoden (det vil si: en av ISTA1003, ISTG1003, ISTT1003).
- Veiledning av prosjektoppgaven annonseres på den eksterne kurssiden: https://wiki.math.ntnu.no/istx100y/2026h/1003
- Informasjon om Prosjektmodulen finnes i Canvas, og alt kursmaterialt er på den eksterne kurssiden: https://wiki.math.ntnu.no/istx100y/2026h/1003

Frist for innlevering av prosjektet til Inspera er mandag 16.november kl 12.00.

Beskrivelse av oppgaven

- I dette prosjektet skal dere arbeide med å analysere et datasett ved å utvikle regresjons-/klassifiseringsmodeller eller klyngeanalyse ved hjelp av statistiske læringsteknikker. Det er et relativt åpent prosjekt, og dere må finne både et datasett og noen relevante spørsmål selv.
- Målet med dette relativt åpne prosjektet er å gi dere praktisk erfaring med metodene som er gjennomgått i kursmodulen ISTx1003, samt å hjelpe dere med å utvikle ferdighetene deres innen databehandling og forhåndsbehandling, modellvalg og evaluering.
- Oppgaven skal utføres i Python, ved hjelp av en Jupyter-notatbok. Dere finner en notatbok med oppgaver fra i fjor her Prosjekt1003_2025.ipynb, og fasiten her Prosjekt1003_2025_solution.ipynb. Se gjennom fjorårets oppgaver for å forstå nivået av metodene dere skal bruke i oppgaven i år.
- Det er meningen at dere skal kjøre notatboken på Jupyterhubben vår https://s.ntnu.no/isthub, eller på deres egen installasjon.

Generell veiledning

For å komme i gang, finner dere her en generell veiledning for prosjektet:

1. Velg et datasett for prosjektet

Dere kan finne et datasett på egen hånd, men vi også lister opp mulige datasett nedenfor:

- **Lego data**: Det var en prosjektoppgave i 2023/2024: Se gjennom hva ble gjort her. Oppgaven var bare for lineær regresjon, men kanskje kan datasettet brukes for en oppgave i år og.

- I Python finnes det flere biblioteker som inneholder mellomstore og store datasett (scikit-learn, statsmodels og seaborn).
- Hvis du er interessert i mer virkelighetsnære og komplekse problemstillinger, er Kaggle et fantastisk sted å lete. Hvis dere velger å bruke et slikt datasett, må dere sørge for at det er tilstrekkelig variert og inneholder nok datapunkter til å kunne trene en god modell. Prøv å søke etter et tema dere synes er interessant og som dere har lyst til å jobbe med. For å finne et «velorganisert» datasett på Kaggle anbefaler vi at dere velger et datasett som har fått et tilstrekkelig høyt antall oppstemmer. Ellers kan datasettet ofte være uorganisert eller dårlig strukturert, med manglende verdier. Vi ønsker ikke at dere skal bruke mye tid på datarensing! Bare noen eksempler:
  - **Boston housing data**: Datasettet er levert av brukeren *Manimala* på Kaggle. Mer informasjon finnes i lenken.
  - **Hjertesvikt (Heart Failure)**: Datasettet er levert av brukeren *Fedesoriano* på Kaggle. Mer informasjon finnes i lenken.
  - **Airbnb-priser i europeiske byer**: Datasettet er levert av brukeren *The Devastator* på Kaggle. Mer informasjon finnes i lenken som er oppgitt. Merk at beskrivelsen sier at datasettet er utviklet for statistisk inferens, men i dette prosjektet skal vi bruke det til regresjon, klassifisering eller klyngeanalyse. Dere kan velge å fokusere på data fra én by, eller kombinere data fra flere forskjellige byer.
  - Finn et datasett med hjelp av KI. Se eksempel instruks gitt i introduksjonsforelesningen (0Intro.pdf).

2. Bestem dere for en prediksjons-/klassifiseringsoppgave/klyngeanalyse.

Viktig: **Bruk metoder fra minst to forskjellige temear i modulen** (regresjon, klassifikasjon, klyngeanalyse).

Tenk nøye gjenneom hva det er dere prøver å forstå, forutsi, klassifisere eller sette i klynger ved hjelp av datasettet? Bestem dere for dette **før** dere prøver ut noen av modellene. Skriv ned noen hypoteser – hva skal dere gjøre, og hva tenker dere å finne? Det er helt greit om det viser seg til slutt at dere ikke klarer å få gode svar eller prediksjoner, så lenge dere har gjort alt på riktig måte. Her er noen forslag, men i prinsippet kan dere velge hva som helst som gir mening. Noen ideer:

- For datasettet om hjertesvikt kan du for eksempel prøve å klassifisere om en pasient får hjertesykdom eller ikke, forutsi alderen deres eller forutsi kolesterolnivået deres.
- For AirBnB-prisdatasettet kan du for eksempel prøve å forutsi prisen eller vurderingen av overnattingsstedet, eller klassifisere romtypen eller om verten har status som «superhost».
- Hvis dere velger et annet datasett, bør dere finne på en oppgave som gir mening ut fra dataene.

3. Databehandling og forbehandling av data.

Før dere bygger modellen, kan det hende at dere må forbehandle dataene (databehandling/data wrangling), avhengig av hvilket format metodene krever.

4. Velg passende modeller og metoder for prosjektet.

Dere skal bare bruke metoder som er tema i denne moduldelen, dvs. regresjon, klassifikasjon eller klyngeanalyse. Sørg for å begrunne valget av algoritme, sjekk modellens forutsetninger. **Det er viktig at dere bare bruker metoder som er tilpasset nivået i dette kurset. Hold det enkelt og realistisk, ikke bruk komplekse metoder som dere ikke forstår, bare fordi KI foreslår det.**

5. Modellevaluering.

Evaluer modellen(e) ved å bruke passende verktøy, for eksempel residualanalyse eller vurdering av prediksjonsytelse (som sensitivitet og spesifisitet i en binær klassifiseringsoppgave).

Generelt:

Uansett hva dere gjør, er det viktig at dere gjør det helt tydelig at dette er deres eget arbeid. Jeg ønsker ikke å se prosjekter som gjør det samme på tvers av gruppene. Dere må også tilpasse analysen til nivået i dette kurset – bruk bare metoder dere lærer om her. Hold det enkelt og realistisk – vi ønsker å se at dere lærer, ikke at dere kopierer.

Bruk av KI og andre hjelpemidler

- Det er lov å bruke KI, men det må komme fram tydelig at dere forstår hva dere gjør.
- Generell veiledning om bruk av KI i studentoppgaver finner dere på NTNU sin hjemmeside – les nøyaktig: https://i.ntnu.no/wiki/-/wiki/Norsk/Kunstig+intelligens+i+bachelor-+og+master
- Bruk av alle KI eller andre hjelpemidler må deklareres. **Bruken av KI skal deklareres på siste side i rapporten.** Denen siden er ikke inkludert i de 10 sidene i rapporten.
- I **gradering av rapporten** vurderer jeg også arbeidets lesbarhet, ikke bare korrektheten. Jeg opplever ofte at KI-generert eller språkvasket tekst blir upresis. Dere må gjennomtenke hva dere vil si og skrive, ikke bare overta KI-genererte forslag uten kritisk vurdering.
- **Gradering av presentasjonen**: Jeg ønsker ikke å se en ordrett gjengivelse av manuskripter eller AI-generert tekst. **Jeg ønsker å se deres forståelse**. Presentasjonen skal ikke gi inntrykk av å være laget av KI.
- I vår første online undervisningstime sammen skal jeg snakke litt mer om hvordan dere kan bruke KI, og hva som ikke er tillat.

Praktiske aspekter (les nøyaktig!)

- Problemstillingen skal defineres først, og ikke endres i ettertid når dere ser resultatene. En god rapport er ikke ekvivalent med spennende resultater – å svare at "vi har ikke grunnlag for å svare på problemstillingen" (med analyser og begrunnelser) er også et godt svar. Hvis dere er usikker, sjekk med faglærer (Steffi) eller en av studentassistentene at problemstillingen deres er god før dere begynner.
- Rapporten skal være på maksimalt 10 sider (ikke inkludert referanser, kode og KI deklarasjon), skrevet med Times New Roman skriftstørrelse 12, Calibri (body) skriftstørrelse 11, eller lignende. Kun de første 10 sidene rettes!!
- Rapporten skal **inneholde figurer** som beskriver dataene og hovedfunnene (husk relevante navn på akser).
- **Koden dere har brukt skal IKKE inkluderes underveis i rapporten**, men til slutt som en Appendix (eller la koden være tilgjengelig på nett). Koden teller ikke til de 10 sidene i rapporten.
- Dere skal også innlevere en videopresentasjon hvor gruppen presenterer oppgaven. **Maksimalt 8 minuter lengde og 10 lysark, og alle gruppemedlemmer må presentere minst en del**. Dere trenger ikke å vise videopptak av ansiktene deres, for å beholde innleveringen anonym.
- I tillegg til at rapporten inneholder relevante analyser og faglig innhold, legges det også vekt på at den er **sammenhengende og ryddig**. Husk å forklare teori, metoder og begreper, referere til kilder dere bruker, og å rapportere, tolke og diskutere relevante modeller, tall og resultater. Bruken av KI deklareres separate (se over). Lærebok, kompendier og videoer er helt greit å referere til.
- **Bonustips**: Oversiktlige og ryddige rapporter er lettere å forstå og kan bidra til en bedre karakter – ganske enkelt fordi vi ikke kan gi full uttelling dersom ting er uklare, tvetydige eller rotete. Tenk deg at oppgaven du har valgt, ble gitt til deg av sjefen din i en bedrift, og at rapporten er det du skal levere til sjefen. Når du skriver rapporten, bør du ha i bakhodet at sjefen har begrenset med tid og oppmerksomhet, og ikke har brukt like mye tid som deg på å sette seg inn i problemstillingen.

Prosjektmal/template

Vi har laget et mal for prosjektet: https://wiki.math.ntnu.no/istx100y/2026h/1003#prosjektoppgaven. Det kommer som latex og pdf fil, og dere kan selv bestemme hva dere bruker. Dere må innlevere en pdf til slutt.

Innlevering

Dere skal innlevere 2 filer:

- En rapport av **maksimal 10 sider** lengde. Viktig at dere bruker rapportmalet på den eksterne kurssiden: https://wiki.math.ntnu.no/istx100y/2026h/1003#prosjektoppgaven. **Viktig: Deklarasjon av KI bruk er del av rapporten, men teller ikke i de 10 sidene.**
- En videopresentasjon av **maksimalt 8 minuter lengde**.

Prosjektet leveres i Inspera, se informasjon om dette på Canvas.

Kontakt eksamenskontoret ved problemer. Det kan **ikke** gis utsettelse på innleveringsfristen.

Gradering av prosjektet

- Oppgaven gir maksimalt 100 poeng, hvorav maksimalt 50 poeng kan oppnås for rapporten og 50 poeng for videopresentasjonen. Både rapporten og presentasjonen vurderes etter følgende kriterier:
  - **Faglig nivå**: Er nivået tilpasset kurset – verken for lavt eller for høyt?
  - **Korrekthet:** Er de anvendte metodene korrekte og tilpasset spørsmålet som skal besvares? Er argumentasjonen i rapporten korrekt og forståelig?
  - **Presentasjon og lesbarhet:** Kommer det frem at dere har forstått hva dere gjør? Er rapporten lett å følge? Har den en oversiktlig, logisk og god struktur?

- Ut fra poengsummen bruker vi prosentvurderingsmetoden med følgende skala:

