Introduksjon

ISTx1003 Statistisk læring og Data Science

Stefanie Muff, Institutt for matematiske fag

Oktober 2026

Plan for i dag

- Læringsmål og plan for prosjektmodulen ISTx1003.
- De tre temaene i modulen:
  - Regresjon
  - Klassifikasjon
  - Klyngeananlyse
- Pensum og læringsressurser
- Prosjektoppgaven og Canvas-informasjon
- Bruk av KI og andre hjelpemidler

Hvem er vi?

- **Studentene**: BIDATA og BDIGSEC, omtrent 250 studenter totalt.
- **Faglig ansvarlig** for innholdet i modulen er Stefanie Muff (stefanie.muff@ntnu.no).
- I **veilederteamet** (for prosjektet) inngår i tillegg
  - Trondheim: studentassistentene Morten Egeberg Christiansen og Oscar Kehinde Asplin Martins
  - Gjøvik: Bare digital veiledning
  - Ålesund: Digital veiledning og support av Siebe B. van Albada

Hva er statistisk læring og data science?

- *Statistisk læring* inneholder stort sett alle metoder som hjelper oss å lære av data.

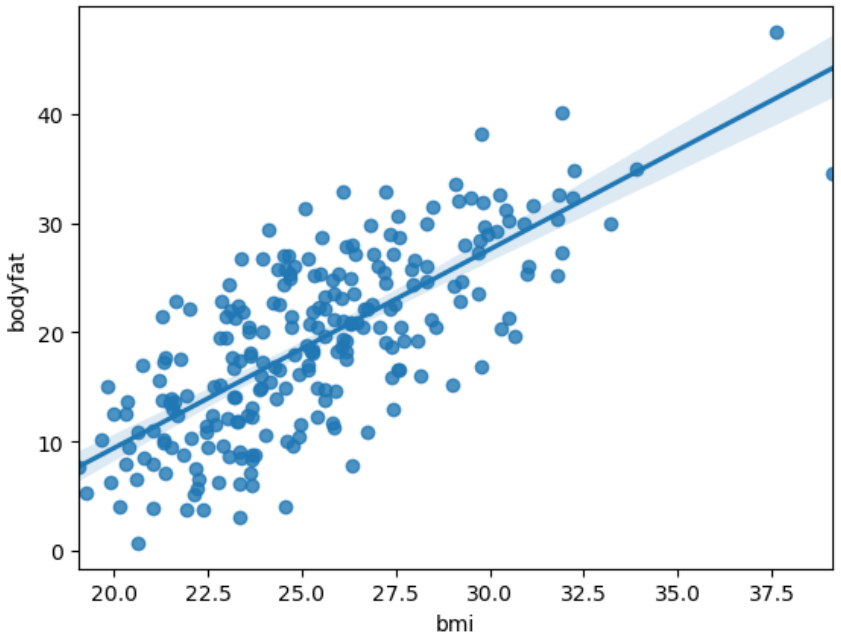
- *Data science* er et konsept for å forene statistikk, dataanalyse, informatikk og tilhørende metoder for å "forstå og analysere relle fenomener med data".

Læringsmål (av modulen)

Etter du har gjennomført denne modulen skal du kunne:

- forstå når du kan bruke regresjon, klassifikasjon og klyngeananlyse til å løse et ingeniørproblem
- kunne gjennomføre multippel lineær regresjon på et datasett
- bruke logistisk regresjon og nærmeste nabo for å utføre en klassifikasjonsoppgave
- bruke hierarkisk og k-means klyngeanalyse på et datasett, forstå begrepet avstandsmål
- kunne kommunisere resultatene fra regresjon/ klassifikasjon/klyngeanalyse til medstudenter og ingeniører
- bli en kritisk leser av resultater fra statistikk/maskinlæring/ statistisk læring/data science/kunstig intelligens når disse rapporteres i media, og forstå om resultatene er realistiske ut fra informasjonen som gis
- kunne jobbe med prosjektoppgaven på en god måte!

Tema 1: Regresjon (enkel og multippel)



Fra en til flere forklaringsvariabler:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + ... + \beta_p x_{pi} + \epsilon \ .$$

Tema 2: Klassifikasjon

Eksempler:

- Hvilke tall er handskrevet på brev? Og hva er sannsynligheten for de ulike tallene (=klasser)?

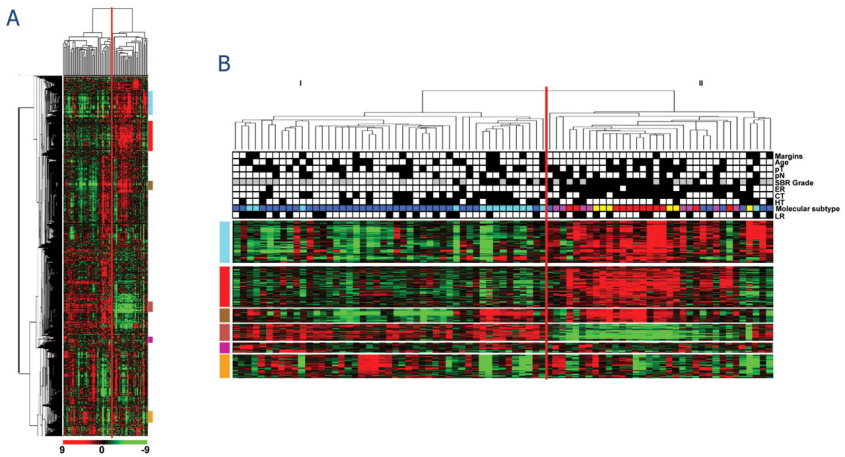


- "Spam eller ham?" spam filer: Klassifikasjon om en e-post er spam eller ikke.
  Binær: Respons variable er "ja"/"nei" (1/0).

Tema 3: Klyngeanalyse

Mål: Finn struktur i dataene. Men vi vet ikke den riktige løsningen (vi har ingen respons, unsupervised learning).

Eksempel: Genaktivitet



- Hvilke celleprøver fra brystkreftpasienter ligner hverandre mest?
- Kan vi finne ukjente klynger (av celleprøver) i dataene?
- Dette kan hjelpe for å forutse sannsynligheten for en tilbakefall.

Pensum og læringsressurser

Alle ressurser er tilgjengelig her:

https://wiki.math.ntnu.no/istx100y/2026h/1003

Prosjektoppgaven

- Informasjon ligger på Canvas, men hovedsakelig på den eksterne nettsiden https://wiki.math.ntnu.no/istx100y/2026h/1003#prosjektoppgaven
- Karakteren teller 30% til den endelige karakteren.

Veiledning til prosjektoppgaven

Fysisk veiledning for Trondheim:

Alle fredager: 23.10, 30.10., 6.11, og 13.11., 10:15-12:00, F1.

Digital veiledning for Ålesund og Gjøvik:

Veiledning via *Zoom*

- Man 26.10, 2.11. og 9.11., 14:15-15:00
- Tir 27.10., 3.11. og 10.11., 10:15-12:00

Det er et venterom hvor dere må vente til jeg slipper dere inn. Det kan ta litt tid.

Zoom lenke:

https://NTNU.zoom.us/j/95180958388?pwd=qnOSNUYX9DlwJgfb4BDXJj1iAsy8pM.1

Diskusjonsform på Canvas

- Bruk “Diskusjoner” tab i Canvas.
- Åpent 24/7, men stenger fredag, 14.11., 17:00.

Forklaring av prosjektoppgaven

Forberedelser til prosjektoppgaven

1. Gå gjennom pensum på kurssiden. Alle videoer og slides er pensum.
2. Gå gjennom prosjektoppgaven fra i fjor, som var en "gammeldags" spørsmål-svar oppgave: https://github.com/stefaniemuff/ISTx1003/blob/main/Prosjekt2025/Prosjekt1003_2025.ipynb. Denne oppgaven hjelper deg til å forstå nivået av metodene dere skal bruke i oppgaven i år. [1]
3. Lego-oppgaven fra 2023/2024: Se gjennom hva ble gjort her. Oppgaven var bare for lineær regresjon, men kanskje kan datasettet brukes for en oppgave i år og.

[1] Her med løsninger https://github.com/stefaniemuff/ISTx1003/blob/main/Prosjekt2025/Prosjekt1003_2025_solution.ipynb

Noen kommentarer:

- Uansett hva dere gjør, er det **viktig at dere gjør det helt tydelig at dette er deres eget arbeid**. Jeg ønsker ikke å se prosjekter som gjør det samme på tvers av gruppene.

- Dere må også tilpasse analysen til nivået i dette kurset. **Bruk bare metoder dere lærer om her**. Ikke bruk KI-genererte analyser som er utenfor pensum.

- Hold det enkelt og realistisk. **Vi ønsker å se at dere lærer, ikke at dere kopierer**.

Hva skal dere innlevere?

Dere skal innlevere 2 filer:

- En rapport av **maks 10 sider**, som følger rapportmalet på den eksterne kurssiden: https://wiki.math.ntnu.no/istx100y/2026h/1003#prosjektoppgaven .

Viktig: Deklarasjon av KI bruk er del av rapporten, men teller ikke til de 10 sidene, men kommer i tillegg.

- En videopresentasjon hvor gruppen presenterer oppgaven. **Maks 8 minuter lengde, maks 10 lysark**, og alle gruppemedlemmer må presentere minst en del.

Hvordan skal dere innlevere?

- Les om gruppeinnlevering her:
  https://i.ntnu.no/wiki/-/wiki/Norsk/Gruppeinnlevering+i+Inspera+-+for+studenter
- Typen innlevering heter "kandidatstyrte grupper" så én i gruppa må først opprette en gruppe i Inspera og deretter dele kode med resten.
- Alle gruppemedlemmer må være deltagere i gruppa i Inspera for at karakteren skal registreres til dere (det holder ikke med kandidatnr på forsiden).Ellers vil det være "ikke møtt".

Bruk av KI

- Det er lov å bruke KI. Se følgende slides.

Men:

- Det må komme fram tydelig at dere forstår hva dere gjør.

Gradering av rapporten:

- Jeg vurderer også arbeidets lesbarhet, ikke bare korrektheten. Jeg opplever ofte at KI-generert eller språkvasket tekst blir upresis. Dere må gjennomtenke hva dere vil si og skrive, ikke bare overta KI-genererte forslag uten kritisk vurdering.

Gradering av presentasjonen:

- Jeg ønsker ikke å se en ordrett gjengivelse av manuskripter eller KI-generert tekst. Jeg ønsker å se deres FORSTÅELSE. Presentasjonen skal ikke gi inntrykk av å være laget av KI.

Hva er god bruk av KI?

Vi ser sammen på nettsiden

https://i.ntnu.no/hvordan-bruke-kunstig-intelligens-som-student

Fra Gizella Apjok og Ingun Tøndel, Seksjon for læringsstøtte og digitale tjenester, enhet for læring og teknologi:



Praktisk anvendelse - Lære å lære

(Malthe-Sørenssen-utvalget - Utvalget om kunstig intelligens i høyere utdanning)

Studentene må **lære å lære** for å bruke språkmodeller på en god måte.

Dette innebærer at de må forstå

- oppgavene de får
- sin egen rolle i læringsprosessen

→ **støtte i læringsprosessen**

Målet er at når denne støtten fjernes mot slutten, står studentene igjen med **mer kompetanse og kunnskap enn i starten**.

Praktisk anvendelse - Juks

Ved skriftlige innleveringer bør du være tydelig på forventninger:

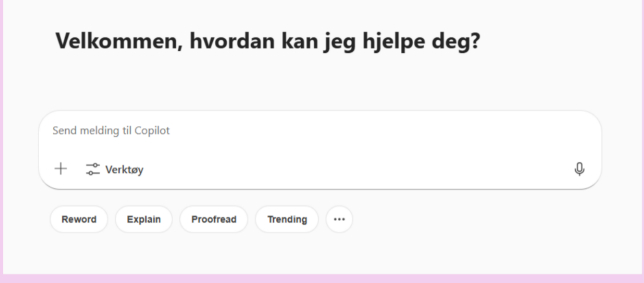


Tekst generert av en språkmodell regnes **ikke** som studentens eget arbeid selv om studenten selv har gitt modellen instrukser.

Hvis en student leverer KI-generert tekst som om den er selvskrevet, regnes det som **juks.**

Kommunikasjon med språkmodellen
→ Instruks (prompt, forespørsel, ledetekst)

Copilot



- rolle
- oppgave
- kontekst
- resultat (output)

Kommunikasjon med språkmodellen → Instruks

(prompt, forespørsel, ledetekst)



Rolle

Hva kan være en aktuell rolle i ditt emne?

Hvilke ulike roller er det aktuelt at studentene samhandler med for å komme frem til gode spørsmål, tema og lignende i ditt emne?

Kommunikasjon med språkmodellen → Instruks

(prompt, forespørsel, ledetekst)



Oppgave

Hva helt konkret skal KI gjøre for deg/for dine studenter? Komme med mange ideer? Stille deg kritiske spørsmål? Gi deg tilbakemelding på ting? Språkvaske teksten din? Her kan du legge tydelige føringer for dine studenters bruk av KI.

Kommunikasjon med språkmodellen → Instruks

(prompt, forespørsel, ledetekst)



Kontekst

Hva handler ditt emne om? Hvilke ulike oppgaver bruker du i ditt emne? Hvilke tidsrammer har du å forholde deg til? Er det oppgaver over lengre tid, som en bachelor- eller masteroppgave, kortere semesteroppgaver, podkaster, videopresentasjoner?

Kommunikasjon med språkmodellen → Instruks

(prompt, forespørsel, ledetekst)



Resultat

Hva sitter man igjen med etter å ha brukt KI i denne oppgaven? På samme måte som man kan ha som mål i oppgaven som underviser at studentene skal være kreative, tenke kritisk og være kildekritisk kan man også sette opp KI til å komme frem til samme resultat.

Et eksempel av en instruks

Det her er bare et eksempel, her for å finne et datasett:

- Rolle: Du er min veileder som hjelper meg å utvikle en problemstilling uten å gi fasitsvar.
- Oppgave: Jeg trenger ideer for et datasett som vi kan analysere i et introduksjonskurs innen statistikk med relativt enkle statistiske metoder. Temaene skal dekke regresjon, klassifikasjon og/eller klyngeanalyse. Datasettet skal være komplekst nok for at analysene ikke er triviale, men samtidig skal datasettet være ryddig og oversiktlig.
- Kontekst: Vi er studenter innen data- og teknologibaserte ingeniørvitenskap. Vi må skrive en oppgave innen 4 uker og levere en rapport på maks 10 sider, i tillegg til en liten presentasjon. Det er et gruppearbeid med 3-6 gruppemedlemmer.
- Resultat: Gi meg forslag til dataset, helst med en (fungerende!) lenke hvor man finner de, uten å bestemme en detaljert analyse eller gjøre analysen for meg. Datasettet kan dekke alle felt, men gjerne foretrekk noen innen naturvitenskap eller helse/medisin. Gjerne list størrelsen og tilgjengelige variable per datasett, og si noe om fordeler og ulemper med forskjelle datasett og analyser. Gjerne si noe om risiko med de forskjellige forslag.

KI bruk til språkvask

- KI kan gjøre språket mer flytende, men **har ikke en menneskelig forståelse av intensjon og kontekst**.
- Den kan derfor **«glatte over» eller endre nyanser og faglig presisjon**.
- Språkvask **kan endre meningen** i teksten uten at man merker det.

Deklarasjon av KI bruk

Siste side på rapporten.

Videre denne uken

- Se på videoene om multippel lineær regresjon (hvis du ikke har allerede gjort det).
- Se på videoene om klassifikasjon.
- Se på videoene om klyngeanalyse.

- Begyn å jobbe med prosjektoppgaven.

- Se her for mer informasjon:
  https://wiki.math.ntnu.no/istx100y/2026h/1003