

Lineær regresjon (enkel og multippel)

ISTx1003 Statistisk læring og Data Science

Stefanie Muff, Institutt for matematiske fag

Oktober 2026

Anerkjennelse

Disse slides bygger på slides fra Mette Langaas, 2020.

Takk til Mette for at jeg fikk bruke noen av materialene.

Læringsmål for regresjon

- Du kan lage en modell for å forstå sammenhengen mellom en respons og én eller flere forklaringsvariabler.
- Du kan lage en modell for å predikere en respons fra en eller flere forklaringsvariabler.


Regresjon – motiverende eksempel

(Veiledet læring - vi kjenner responsen)


- Kroppsfett er en viktig indikator for overvekt, men vanskelig å måle.

Spørsmål: Hvilke faktorer tillater præsis estimering av kroppsfettet?

Vi undersøker 243 mannlige deltakere. Kroppsfett (%), BMI og andre forklaringsvariabler ble målet. Kryssplott:



For en model for fungerer godt for prediksjon trenger vi *multippel lineær regresjon*. Men vi begynner med *enkel lineær regresjon* (bare en forklaringsvariabel):



Enkel lineær regresjon


- En kontinuerlig respons variabel Y
- Bare *en forklaringsvariabel* x_1
- Relasjon mellom Y og x_1 er antatt å være *lineær*.

Hvis den lineære relasjonen mellom Y og x er perfekt, så gjelder

$$y_i = \beta_0 + \beta_1 x_{1i}$$


for alle i . Men..

Hvilken linje er best?



Enkel lineær regresjon

a) Kan vi tilpasse den “rette” linjen til dataene?



- $\hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_{1i}$.
- $\hat{e}_i = y_i - \hat{y}_i$
- $\hat{\beta}_0$ og $\hat{\beta}_1$ velges slik at

$$SSE = \sum_i \hat{e}_i^2$$


- b) Kan vi tolke linja? Hvor sikkert er jeg på $\hat{\beta}_1$ og linja? Vi trenger antakelser, konfidensintervaller, og hypotesetest.
- c) Fremtidige presisjoner av predikert y (kroppsfett)?

Lineær regresjon – antakelser

$$Y_i = \underbrace{\beta_0 + \beta_1 x_{i1}}_{\hat{y}_i} + e_i$$

med

$$e_i \sim N(0, \sigma^2) .$$



Do-it-yourself “by hand”

Her kan du finne de beste parametrene selv:

Bruk denne lenken:

https://gallery.shinyapps.io/simple_regression/


Multippel lineær regresjon

Nesten det samme som enkel lineær regresjon, vi bare summerer flere forklaringsvariabler:

$$Y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \dots + \beta_p x_{pi} + e_i, \quad e_i \sim N(0, \sigma^2) .$$

For eksempel:

$$\text{bodyfat}_i = \beta_0 + \beta_1 \text{bmi}_i + \beta_2 \text{age}_i + e_i .$$



Regresjonsanalyse i fem steg

Steg 1: Bli kjent med dataene ved å se på oppsummeringsmål og ulike typer plott

Steg 2: Spesifiser en matematisk modell

Steg 3: Tilpass modellen





Steg 4: Presenter resultatene fra den tilpassede modellen

Steg 5: Evaluer om modellen passer til dataene


Vi skal ikke snakke så mye om hvordan man finner en god modell, men om hvordan man sammenligner to modeller (med justert R^2) .

Steg 1: Bli kjent med dataene

Vi kan for eksempel se på histogram og boxplot:



Ellers en *parplot* med kryssplotter for alle forklaringsvariable(r) $(x_1, \dots, x_p)$ og respons y :



##	bodyfat	age	weight	height
##	Min. : 0.70	Min. :22.00	Min. : 56.75	Min. :162.6
##	1st Qu.:12.50	1st Qu.:35.50	1st Qu.: 72.30	1st Qu.:173.7
##	Median :19.20	Median :43.00	Median : 80.02	Median :177.8
##	Mean :19.11	Mean :44.83	Mean : 80.91	Mean :178.5
##	3rd Qu.:25.20	3rd Qu.:54.00	3rd Qu.: 89.32	3rd Qu.:183.5
##	Max. :47.50	Max. :81.00	Max. :119.29	Max. :196.8
##	bmi	neck	abdomen	hip
##	Min. :19.06	Min. :31.10	Min. : 70.40	Min. : 85.30
##	1st Qu.:23.07	1st Qu.:36.40	1st Qu.: 84.90	1st Qu.: 95.55
##	Median :25.10	Median :38.00	Median : 91.00	Median : 99.30
##	Mean :25.34	Mean :37.96	Mean : 92.38	Mean : 99.69
##	3rd Qu.:27.34	3rd Qu.:39.40	3rd Qu.: 99.15	3rd Qu.:103.15
##	Max. :39.12	Max. :43.90	Max. :126.20	Max. :125.60

I Python får du en oppsummering av datasettet (df) med `df.describe()`.

Steg 2: Spesifiser modellen

Nå må vi spesifisere en modell med å velge hvilke forklaringsvariabler vi vil bruke

$$y \sim x_1 + x_2 + x_3 .$$

I Python er det

```
formel='y ~ x1 + x2 + x3'.
```

Eksempel 1:

$$\text{bodyfat} \sim \text{bmi}$$

hvis den matematiske modellen er

$$\text{bodyfat}_i = \beta_0 + \beta_1 \text{BMI}_i + e_i ,$$

Python: `formel='bodyfat ~ bmi'`.

Eksempel 2:

$$\text{bodyfat} \sim \text{bmi} + \text{age}$$

hvis den matematiske modellen er

$$\text{bodyfat}_i = \beta_0 + \beta_1 \text{BMI}_i + \beta_2 \text{age}_i + e_i .$$

Python: `formel='bodyfat ~ bmi + age'`.

Steg 3: Tilpass modellen

“Tilpasse” betyr:


- Vi estimerer $\beta_0, \beta_1, \dots$, og vi får estimerer $\hat{\beta}_0, \hat{\beta}_1, \dots$
- I tillegg estimerer vi også σ^2 .

Steg 4: Resultat og tolkning av estimatene

OLS Regression Results						
=====						
Dep. Variable:	bodyfat	R-squared:	0.539			
Model:	OLS	Adj. R-squared:	0.537			
Method:	Least Squares	F-statistic:	281.8			
Date:	Wed, 08 Sep 2021	Prob (F-statistic):	2.06e-42			
Time:	18:58:47	Log-Likelihood:	-761.28			
No. Observations:	243	AIC:	1527.			
Df Residuals:	241	BIC:	1534.			
Df Model:	1					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]


Intercept	-26.9844	2.769	-9.746	0.000	-32.439	-21.530
bmi	1.8188	0.108	16.788	0.000	1.605	2.032

- Tilpasset regresjonslinje og 95% konfidensintervall for regresjonslinja (forventningsverdien $E(Y)$).
- 95% prediksjonsintervall for nye observasjoner (kroppsfett for nye personer; håndtegnet).



Steg 5: Passer modellen?


Tukey-Anscome (TA) diagram:



Her vil man



- Ikke noe struktur
- Sentrering rundt 0 verdien

Kvantil-kvantil plot:



Her ser man at observasjonene ligger mer og mindre på linja.

Hvordan ser det ut når en modell *ikke* passer?



Multipel lineær regresjon

Gjenta samme analyse med to kovariabler
(formel='bodyfat ~ bmi + age'):

OLS Regression Results						
=====						
Dep. Variable:	bodyfat	R-squared:	0.580			
Model:	OLS	Adj. R-squared:	0.577			
Method:	Least Squares	F-statistic:	165.9			
Date:	Wed, 08 Sep 2021	Prob (F-statistic):	5.67e-46			
Time:	19:55:28	Log-Likelihood:	-749.88			
No. Observations:	243	AIC:	1506.			
Df Residuals:	240	BIC:	1516.			
Df Model:	2					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	-31.2545	2.790	-11.203	0.000	-36.750	-25.759
bmi	1.7526	0.104	16.773	0.000	1.547	1.958
age	0.1327	0.027	4.857	0.000	0.079	0.186

Med fem kovariabler:

OLS Regression Results						
=====						
Dep. Variable:	bodyfat		R-squared:	0.726		
Model:	OLS		Adj. R-squared:	0.720		
Method:	Least Squares		F-statistic:	125.3		
Date:	Thu, 09 Sep 2021		Prob (F-statistic):	1.73e-64		
Time:	09:16:49		Log-Likelihood:	-698.26		
No. Observations:	243		AIC:	1409.		
Df Residuals:	237		BIC:	1429.		
Df Model:	5					
Covariance Type:	nonrobust					
=====						
	coef	std err	t	P> t	[0.025	0.975]

Intercept	-35.2802	6.073	-5.809	0.000	-47.245	-23.316
bmi	0.3881	0.224	1.730	0.085	-0.054	0.830
age	0.0038	0.027	0.141	0.888	-0.050	0.058
weight	-0.1141	0.029	-3.883	0.000	-0.172	-0.056
neck	-0.4581	0.216	-2.123	0.035	-0.883	-0.033
abdomen	0.8888	0.085	10.486	0.000	0.722	1.056
=====						

Hva betyr alt dette?

- coef: $\hat{\beta}_j$
- std err: $\hat{SE}(\hat{\beta}_j)$
- t: $\frac{\hat{\beta}_j - 0}{\hat{SE}(\hat{\beta}_j)}$
- P>|t|: p -verdi (obs! $p = 0.000$ er *ikke* mulig, det betyr egentlig $p < 0.0005$)

Hva betyr alt dette?

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-35.2802	6.073	-5.809	0.000	-47.245	-23.316
bmi	0.3881	0.224	1.730	0.085	-0.054	0.830
age	0.0038	0.027	0.141	0.888	-0.050	0.058
weight	-0.1141	0.029	-3.883	0.000	-0.172	-0.056
neck	-0.4581	0.216	-2.123	0.035	-0.883	-0.033
abdomen	0.8888	0.085	10.486	0.000	0.722	1.056

Prediksjon:

$$\hat{y} =$$

Prediker bodyfat for en ny person med
bmi=25, age=50, weight=75, neck=40, abdomen=95:

$$\hat{y} =$$

$$= 21.88$$

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-35.2802	6.073	-5.809	0.000	-47.245	-23.316
bmi	0.3881	0.224	1.730	0.085	-0.054	0.830
age	0.0038	0.027	0.141	0.888	-0.050	0.058
weight	-0.1141	0.029	-3.883	0.000	-0.172	-0.056
neck	-0.4581	0.216	-2.123	0.035	-0.883	-0.033
abdomen	0.8888	0.085	10.486	0.000	0.722	1.056

- Hva betyr $\hat{\beta}_0$?
- Hva betyr $\hat{\beta}_{abdomen} = 0.89$?

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-35.2802	6.073	-5.809	0.000	-47.245	-23.316
bmi	0.3881	0.224	1.730	0.085	-0.054	0.830
age	0.0038	0.027	0.141	0.888	-0.050	0.058
weight	-0.1141	0.029	-3.883	0.000	-0.172	-0.056
neck	-0.4581	0.216	-2.123	0.035	-0.883	-0.033
abdomen	0.8888	0.085	10.486	0.000	0.722	1.056



- 95% konfidensintervall: Intervall vi har stor tro at den inneholder den sanne stigningen β_j .
- $$[\hat{\beta}_j \pm \underbrace{t_{\alpha/2, df}}_{\approx 1.96} \cdot \text{SE}(\hat{\beta}_j)]$$

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-35.2802	6.073	-5.809	0.000	-47.245	-23.316
bmi	0.3881	0.224	1.730	0.085	-0.054	0.830
age	0.0038	0.027	0.141	0.888	-0.050	0.058
weight	-0.1141	0.029	-3.883	0.000	-0.172	-0.056
neck	-0.4581	0.216	-2.123	0.035	-0.883	-0.033
abdomen	0.8888	0.085	10.486	0.000	0.722	1.056

- p -verdier og hypotesetester

Recap: Formell definisjon av p -verdien

p -verdien er sannsynligheten for det vi *har* observert eller noe mer ekstremt, dersom H_0 er sant.



R^2 og justert R^2

```
Dep. Variable:          bodyfat    R-squared:                0.726
Model:                  OLS        Adj. R-squared:           0.720
Method:                 Least Squares    F-statistic:             125.3
Date:                  Thu, 09 Sep 2021    Prob (F-statistic):      1.73e-64
Time:                  09:16:49          Log-Likelihood:          -698.26
No. Observations:      243             AIC:                    1409.
Df Residuals:          237             BIC:                    1429.
Df Model:               5
Covariance Type:       nonrobust
```

$$R^2 = \frac{\text{TSS} - \text{SSE}}{\text{TSS}} = 1 - \frac{\text{SSE}}{\text{TSS}} = 1 - \frac{\sum_{i=1}^n (y_i - \hat{y}_i)^2}{\sum_{i=1}^n (y_i - \bar{y})^2},$$

med

$$\text{TSS} = \sum_{i=1}^n (y_i - \bar{y})^2$$



som måler den totale variabiliteten i $(y_1, \dots, y_n)$.

Problemet med R^2 : Verdien blir alltid større når flere variabler er lagt til.

For modellvalg bruker vi derfor en justert versjon:

$$R_{adj}^2 = 1 - (1 - R^2) \frac{n - 1}{n - p - 1}$$

TA og kvantil-kvantil plot



Binære forklaringsvariabler

Den enkleste modellen er

$$y_i = \beta_0 + \beta_1 x_{1i} + e_i .$$

Hva betyr det når x_{1i} er enten 0 eller 1 (binær)?

$$\begin{array}{ll} \beta_0 + e_i & \text{hvis } x_{1i} = 0 , \\ \beta_0 + \beta_1 + e_i & \text{hvis } x_{1i} = 1 . \end{array}$$

Eksempel: Studie om kvikksølv (Hg)

Modell:

$$\log(Hg_{urin})_i = \beta_0 + \beta_1 \cdot x_{1i} + \beta_2 \cdot x_{2i} + \beta_3 \cdot x_{3i} + e_i ,$$

Med

- $\log(Hg_{urin})$: log konsentrasjon av Hg i urin.
- x_1 binær variabel som er 1 hvis person røyker, ellers 0
- x_2 antall amalgam fillinger i tennene.
- x_3 antall fiskemåltider per måned.

Interpretasjon av regresjon med binær variabel

	coef	std err	t	P> t	[0.025	0.975]
Intercept	-2.1136	0.100	-21.101	0.000	-2.311	-1.916
smoking	0.3317	0.257	1.292	0.198	-0.175	0.839
amalgam_quant	0.1799	0.039	4.566	0.000	0.102	0.258
fisk_quant	0.0678	0.017	4.088	0.000	0.035	0.101

Modell for røyker:

Modell for ikke-røyker:

Kategoriske forklaringsvariabler

- Vi gjør ting enda mer fleksible (eller kompliserte!) når vi også tillater kategoriske forklaringsvariabler.
- Eksempel med 3 kategorier: Bildatasett med y =bensinforbruk og forklaringsvariabler **vekt** og **origin** som er en av de tre kategoriene {American,European,Japanese}.

```
formel='mpg ~ vekt + origin'
```

- Idé: dummy-variabel koding – kalles *one-hot koding* i maskinlæring.
 - $x_{2i} = 0$ og $x_{3i} = 0$ hvis **origin** er “American”
 - $x_{2i} = 1$ og $x_{3i} = 0$ hvis **origin** er “European”
 - $x_{2i} = 0$ og $x_{3i} = 1$ hvis **origin** er “Japanese”

Modellen: $y_i = \beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i} + \beta_3 x_{3i} + e_i$

```

=====
Dep. Variable:          mpg      R-squared:                0.702
Model:                  OLS      Adj. R-squared:           0.700
Method:                 Least Squares      F-statistic:           304.7
Date:                   Mon, 13 Sep 2021    Prob (F-statistic):     1.28e-101
Time:                   14:42:02           Log-Likelihood:         -1123.9
No. Observations:       392              AIC:                   2256.
Df Residuals:           388              BIC:                   2272.
Df Model:                3
Covariance Type:        nonrobust
=====

```

	coef	std err	t	P> t	[0.025	0.975]
Intercept	43.7322	1.113	39.277	0.000	41.543	45.921
origin[T.European]	0.9709	0.659	1.474	0.141	-0.324	2.266
origin[T.Japanese]	2.3271	0.665	3.501	0.001	1.020	3.634
weight	-0.0070	0.000	-21.956	0.000	-0.008	-0.006

```

=====

```

Så hva er modellene for de tre opprinnelsene (**origin**) av bilene?