

Klassifikasjon

ISTx1003 Statistisk læring og Data Science

Stefanie Muff, Institutt for matematiske fag

Oktober 21 og 27, 2025

Anerkjennelse

Disse slides bygger på slides fra Mette Langaas, 2020.

Takk til Mette for at jeg fikk bruke noen av materialene.

Plan tema “Klassifikasjon”

- Læringsmål og ressurser
- Hva er klassifikasjon?
- Trening, validering og testing (3 datasett)
- k -nærmeste nabo (KNN): en intuitiv metode
- Forvirringsmatrise og feilrate for evaluering av metoden
- Logistisk regresjon

Læringsmål

- kunne forstå hva klassifikasjon går ut på og kjenne situasjoner der klassifikasjon vil være en aktuell metode å bruke
- kjenne begrepene *treningssett*, *valideringssett* og testsett og forstå hvorfor vi lager dem og hva de skal brukes til
- vite hva en forvirringsmatrise er, og kjenne til begrepene *feilrate* (error rate) og *nøyaktighet* (accuracy)
- forstå tankegangen bak k -nærmeste nabo-klassifikasjon, valg av k
- kjenne til modellen for logistisk regresjon, og kunne tolke de estimerte koeffisientene
- forstå hvordan vi utfører klassifikasjon i Python
- kunne besvare problem 2 av prosjektoppgaven

Læringsressurser

Tema Klassifikasjon:

- **Korte videoer:** (by Mette Langaas)
 - Introduksjon og k -nærmeste nabo klassifiasjon (10:58)
 - Logistisk regresjon (14:17)
- Denne forelesningen
- **Disse slides** med notater

Klassifikasjon – hva er det?

- Mål:
 - tilordne en ny observasjon til en av flere *kjente* klasser
 - lage en klassifikasjonsregel
 - estimere sannsynligheten for at en ny observasjon tilhører de ulike klassene

For hver av de uavhengige observasjonene $i = 1, \dots, n$ har vi

- Forklaringsvariabler $(x_{1i}, x_{2i}, \dots, x_{pi})$
- En kategorisk responsvariablel y_i .

Eksempel I

- Hvilke tall er handskrevet på brevet? Og hva er sannsynligheten for de ulike tallene (=klasser)?



- Kommer en gitt kunde til å betale tilbake lånet sitt?
- Prognose om noen blir syk (hjertesykdom, kreft...) og sannsynligheten for det.

Eksempel II


Problem 2 i prosjektet:

“Spam eller ham?” Spam filter: Klassifikasjon for å finne ut om en e-post er spam eller ikke (=“ham”).

Binær: Respons variable er “ja”/“nei” (1/0).

Syntetisk eksempel

- Et datasett med følgende struktur: (x_{1i}, x_{2i}, y_i) .




Spørsmål vi vil besvare: Hva er de beste klassifikasjonsgrensene?

Et reelt eksempel

Flipper and bill length

Dimensions for Adelie, Chinstrap and Gentoo Penguins at Palmer Station LTER



<https://github.com/allisonhorst/palmerpenguins>

Data

Datasett: $(x_{1i}, x_{2i}, \dots, x_{pi}, y_i)$


Vi må dele datasettet i tre deler:

- Treningsdata
- Valideringsdata
- Testdata



Hvorfor det?

Trening-, validering- og testsett for syntetiske data



k -nærmeste-nabo-klassifikasjon

For å *finne* klassifikasjonsregelen bruker vi bare treningsdataene.

Algoritmen:

- 1) Ny observasjon: $x_0 = (x_{1,0}, x_{2,0}, \dots, x_{p,0})$. Hvilken klasse bør denne klassifiseres til?
- 2) Finn de k nærmeste naboene til observasjonen i treningssettet.
- 3) Sannsynligheten for at den nye observasjonen tilhører klasse 1 anslår vi er andelen av de k nærmeste naboene som tilhører klasse 1. Ditto for de andre klassene.
- 4) Klassen til den nye observasjonen er den som har størst sannsynlighet. Det blir det samme som å bruke flertallsavstemming.


k -nærmeste-nabo-klassifikasjon

Tre spørsmål:

- Hva betyr “nærmest”? Vi trenger en definisjon av avstand.
- Hvilke verdier kan k ha?
- Hvordan bestemmer vi k ?

Hva betyr nærmest?

Nærmest er definert ved å bruke Euklidsk avstand.




Euklidsk avstand:


$$D_E(i, 0) = \sqrt{\sum_{j=1}^p (x_{ji} - x_{j0})^2}$$

Andre avstandsmål kan også brukes, men Euklidsk avstand er mest vanlig.


Nærmeste naboer



Nærmeste naboer




Tegne klassegrenser




Hvordan ser klassegrensene ut?

Husk: Vi bruker treningssettet for å finne klassifikasjonsregelen:



Hvordan ser klassegrensene ut?

Svar: It depends!



Men vent... hvordan velger vi k da?

Vi så jo at

- hvis man velger k for lite, da blir grensen *for fleksibel*.

Men:

- hvis man velger k for stor, kan grensen bli *for uflexibel*.

Det er noe som kalles en *trade-off*, og vi skal bruke valideringssettet for å få en idé om kvaliteten i klassifikasjonen.


Forvirringsmatrise

Forvirringsmatrise med to klasser:


	Sann klasse 0	Sann klasse 1
Predikert klasse 0	Sann negativ (TN)	Falsk negativ (FN)
Predikert klasse 1	Falsk positiv (FP)	Sann positiv (TP)

- **Feilrate:** andel feilklassifiserte observasjoner.
- Derfor: Vi velger den k som minimerer feilraten på *valideringssettet* (ikke trainingssettet!).

Marker og tell antall gale klassifiseringer på valideringssettet ($k = 1$):




Igjen, men nå med $k = 99$:




Feilrate i valideringssettet

Det kan vi nå systematisk gjøre med alle $k = 1, 3, \dots, k \leq n$:



Klassegrensene ser ganske likt ut for $k \geq 15$:



Data


Husk at vi hadde *tre* deler i datasettet:

- **Treningssett:** For å lage en klassifikasjonsregel
- **Valideringssett:** For å finne på optimale hyperparametere
- **Testsett:** For å evaluere regelen på fremtidige data



Nå kan vi bruke testsettet for å *finne feilraten* for fremtidige data.

Feilraten på testsettet for KNN med $k = 15$ (egentlig er $k = 31$ best, men det gjør ikke en stor forskjell):



Feilraten er 0.09.

k -nærmeste nabo klassifikasjon i Python

```
knaboer = np.arange(1,101,step=2)
val_feilrate = np.empty(len(knaboer))
for i,k in enumerate(knaboer):
    knn = KNeighborsClassifier(n_neighbors=k,p=2)
    knn.fit(df_tren[['x1','x2']], df_tren['y'])
    val_feilrate[i] = 1-knn.score(df_val[['x1','x2']],
df_val['y'])
```

Se prosjektoppgaven for mer Python kode.

Plan tema “Klassifikasjon”

- Læringsmål og ressurser
- Hva er klassifikasjon?
- Trening, validering og testing (3 datasett)
- k -nærmeste nabo (KNN): en intuitiv metode
- Forvirringsmatrise og feilrate for å evaluere metoden
- Logistisk regresjon

Logistisk regresjon - mål

- Forstå modellen
- Tolke estimerte koeffisienter
- Hypotesetest og p -verdi
- Velge mellom modeller
- Kunne utføre dette i Python

Logistisk regresjon

- Kan bare handtere *to klasser* $y_i \in \{0, 1\}$.
- Vi antar at Y_i har en **Bernoulli fordeling** med suksesssannsynlighet p_i , derfor:

$$y_i = \begin{cases} 1 & \text{med sannsynlighet } p_i, \\ 0 & \text{med sannsynlighet } 1 - p_i. \end{cases}$$

- **Mål:** For forklaringsvariabler $(x_{1i}, x_{2i}, \dots, x_{pi})$ vi vil estimere $p_i = \Pr(y_i = 1 \mid x_1, \dots, x_p)$.


Eksempel: Kredittkort data

Datasettet `Default` er tatt fra her:



<https://rdrr.io/cran/ISLR/man/Credit.html>

Mål : å forutsi om en person ikke betaler kredittkortregningen (“person defaults”), avhengig av årsinntekten (income) og balansen på kredittkortet (balance).

Orange: `default=yes`, blue: `default=no`.




Det ser ut som at “Balance” er en ganske god forklarende variabel til Default (nei/ja), mens “Income” ikke har mye å si.



Kan vi bare bruke lineær regresjon for binær klassifikasjon?



For en binær responsvariabel $Y = \text{yes}$ or no , og forklaringsvariabler X bruker vi vanligvis en *dummy encoding* :

$$Y = \begin{cases} 0 & \text{hvis no ,} \\ 1 & \text{hvis yes .} \end{cases}$$




- Kunne vi da ikke bare formulere en lineær regresjonsmodell for Y vs. X ?
- Vi kunne jo klassifisere responsen som “ja” (1) hvis den estimerte sannsynligheten er $P(Y = 1) > 0.5$.
- Problemet med lineær regresjon: Vi kan forutsi $P(Y = 1) < 0$ eller $P(Y = 1) > 1$ med modellen, men en sannsynlighet er alltid mellom 0 og 1.

For kredittortdatasettet:



Vi trenger logistisk regresjon!



Enkel logistisk regresjon

- Vi antar at responsen Y_i er binomisk fordelt med suksessannsynlighet p_i .
- **Ideen:** å koble p_i sammen med forklaringsvariablen med en logistisk funksjon:


$$p_i = \frac{\exp(\beta_0 + \beta_1 x_{1i})}{1 + \exp(\beta_0 + \beta_1 x_{1i})} .$$

- Denne verdien p_i er alltid mellom 0 og 1, som den skal være.

Klassifikasjonsregel

I kredittkorteksempelet er x_{1i} balansen til person i .

Klassifikasjonsregel: $p \geq 0.5$ vs $p < 0.5$.



Enkel logistisk regresjon med Python

Logit Regression Results						
=====						
Dep. Variable:	y	No. Observations:	6000			
Model:	Logit	Df Residuals:	5998			
Method:	MLE	Df Model:	1			
Date:	Fri, 03 Sep 2021	Pseudo R-squ.:	0.4726			
Time:	19:08:50	Log-Likelihood:	-460.65			
converged:	True	LL-Null:	-873.50			
Covariance Type:	nonrobust	LLR p-value:	1.403e-181			
=====						
	coef	std err	z	P> z	[0.025	0.975]

Intercept	-11.0385	0.488	-22.599	0.000	-11.996	-10.081
balance	0.0057	0.000	19.386	0.000	0.005	0.006
=====						

Tolkning av β_1 : odds

- Odds er definert som ratioen mellom sannsynlighet for suksess (p) og fiasko ($1 - p$):

$$odds = \frac{p}{1 - p}$$

- En liten quiz: Dra til www.menti.com
- I logistisk regresjon: Hvis vi øker verdien til kovariaten fra x_{i1} til $x_{i1} + 1$ så blir den nye oddsen lik den gamle multiplisert med e^{β_1} .

Enkel logistisk regresjon

	coef	std err	z	P> z	[0.025	0.975]
Intercept	-11.0385	0.488	-22.599	0.000	-11.996	-10.081
balance	0.0057	0.000	19.386	0.000	0.005	0.006

- $\beta_0 = -11.0385$, $\beta_1 = 0.0057$.
- $e^{0.0057} = 1.0057$: Hvis **balance** øker med 1, går oddsen opp med *faktor* 1.0057.
- $e^{0.0057 \cdot 100} = 1.768$: Hvis **balance** øker med 100, går oddsen opp med *faktor* 1.768.
- Husk at $H_0 : \beta_1 = 0$ versus $H_1 : \beta_1 \neq 0$. Her har vi $p < 0.0005$ for testen, derfor forkaster vi H_0 .

Logistisk regresjon med flere forklaringsvariabler

	coef	std err	z	P> z	[0.025	0.975]
Intercept	-11.6549	0.574	-20.307	0.000	-12.780	-10.530
balance	0.0058	0.000	19.256	0.000	0.005	0.006
income	1.471e-05	6.51e-06	2.259	0.024	1.95e-06	2.75e-05

- Nytt:

$$p_i = \frac{\exp(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i})}{1 + \exp(\beta_0 + \beta_1 x_{1i} + \beta_2 x_{2i})}$$

- Tolkning av β_1 og β_2 ?
- p -verdi?

Hvilken model er best?

- For klassifikasjonen, skal vi velge modellen med bare **balance** eller med **balance + income**?
- Ideen: Skjekk feilraten *på valideringssettet*!
- Husker du bruken av forvirringsmatrisen?
- Det er resultatene fra modellene:

	pred:no	pred:yes
true:no	1923	10
true:yes	52	15

	pred:no	pred:yes
true:no	1924	9
true:yes	50	17

- Feilratene er derfor 0.031 (enkel modell) og 0.0295 (multippel modell)

Feilrate testsett

Til slutten kan vi sjekke feilraten på testsettet – dette settet har vi enda ikke brukt.

Her finner vi 0.0245

Python code

```
formel='y ~ balance + income'
modell = smf.logit(formel,data=df)
resultat = modell.fit()
resultat.summary()
print(np.exp(resultat.params))

cutoff = 0.5
test_pred = resultat.predict(exog = df_test)
y_testpred = np.where(test_pred > cutoff, 1, 0)
y_testobs = df_test['y']
print("Feilrate:", 1-accuracy_score(y_true=y_testobs,
    y_pred=y_testpred,normalize=True))
```

Videre denne uken

- Se på videoene om Klyngeanalyse og K-gjennomsnitt (vent med videoen om hierarkisk klyngeanalyse).
- Begynn å jobbe med prosjektoppgaven.
- Se her for mer informasjon:
<https://wiki.math.ntnu.no/istx100y/2025h/1003>