Klyngeanalyse

ISTx1003 Statistisk læring og Data Science

Stefanie Muff, Institutt for matematiske fag

Oktober/November, 2026

Anerkjennelse

Disse slides bygger på slides fra Mette Langaas, 2020.

Takk til Mette for at jeg fikk bruke noen av materialene.

Plan for i dag (tema “Klyngeanalyse”)

- Hva er klyngeanalyse?
- Læringsmål, pensum og læringsressurser
- Avstandsmål
- K-gjennomsnitt (“K-means”) klyngeanalyse
- Bruk av klyngeanalyse på et bilde
- Hierarkisk klyngeanalyse
- Informasjon om prosjektet

Eksempel 1: Genaktivitet

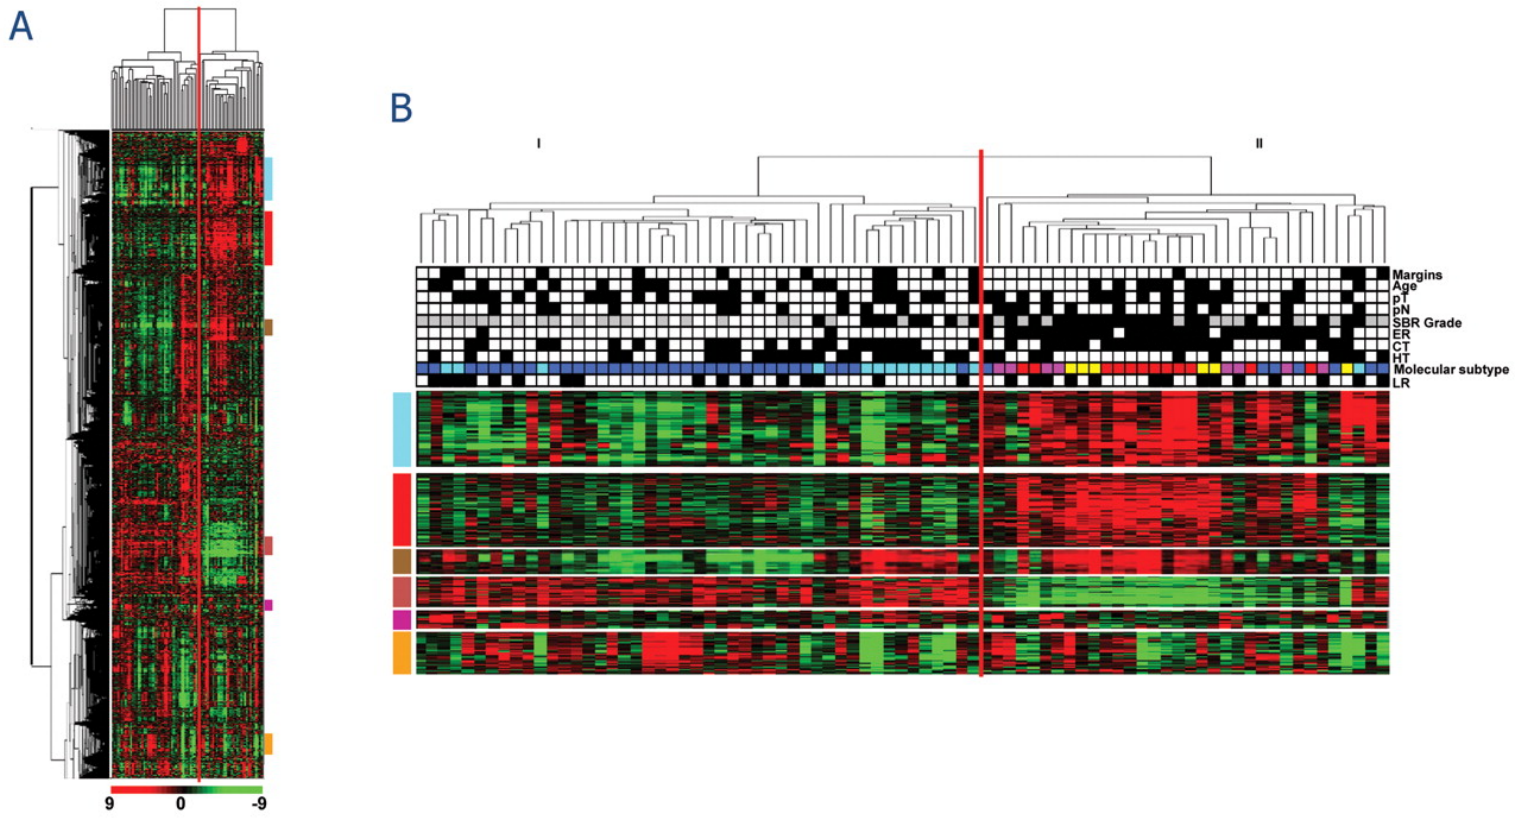
- $n = 81$ celleprøver fra kreftsvulster til ulike pasienter
- Genaktivitet for $p = 12957$ gener

Spørsmål:

Hvilke celleprøver fra brystkreftpasienter ligner hverandre mest?

Kan vi finne ukjente klynger (av celleprøver) i dataene?

Dette kan hjelpe for å forutsi sannsynligheten for en tilbakefall.



$$X = p \times n = \text{gener} \times \text{prøver} \ .$$

Finn ut mer: https://cgp.iiarjournals.org/content/8/4/199

Eksempel 2: Proteininteraksjonsnettwerk

Kan vi finne klynger med relatert funksjon?

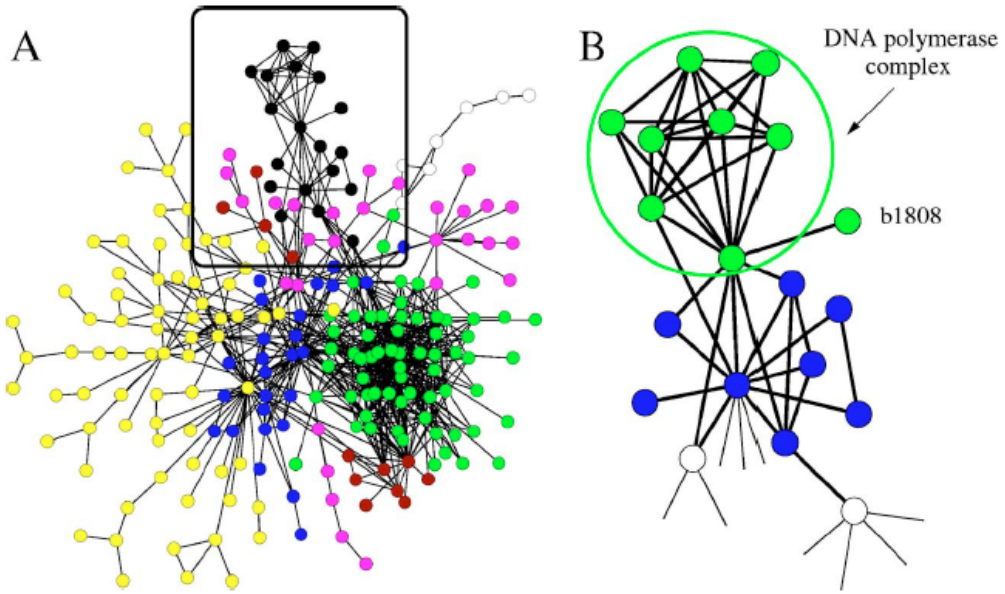


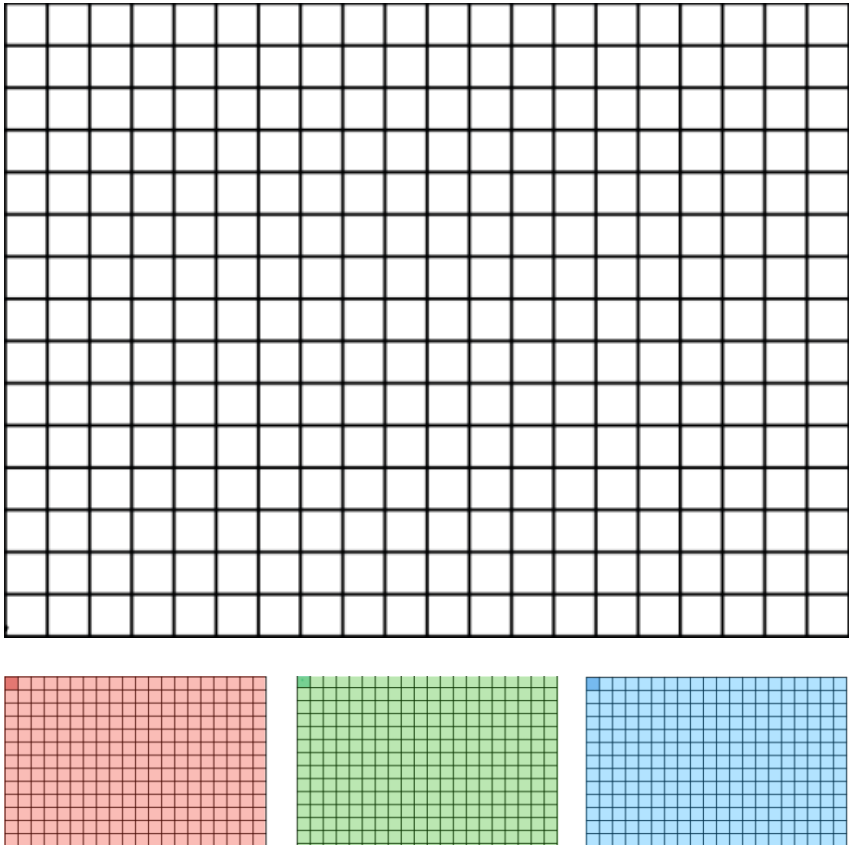
FIG. 4. (Color online) (a) Largest connected component of the PPI of *E. coli*. The colors represent the clusterization found by optimizing modularity. (b) *LQ* clusterization of the black *Q* cluster. The green circle contains proteins belonging to the DNA polymerase complex. The unknown protein b1808 is assigned to this complex according to *LQ* while the complete *Q* cluster is heterogeneous.

Eksempel 3: Bildanalyse

Mål:

Å bruke klyngeanalyse til å fjerne detaljer og støy - ved å dele pikslene inn i to eller flere klynger.

Hver piksel har en farge som er definert som en blandig av rød, grønn og blå (x, y, z):



Klyngeanalyse: Finn k "typiske farger" som representerer klynger (sentroider) og erstatt hver piksel med sentroidfargen.

Jeg var litt nysgjerrig...

Opprinnelig bilde



Jeg var litt nysgjerrig...

Opprinnelig bilde



Bilde i svart/hvitt



Jeg var litt nysgjerrig...

Opprinnelig bilde



Bilde i svart/hvitt



bilde med 8 klynger



Læringsmål

- Forstå hvorfor det er interessant å gjøre klyngeanalyse
- Kjenne igjen situasjoner der klyngeanalyse vil være en aktuell metode å bruke
- Kjenne begrepene avstandsmål, koblingstype, dendrogram
- Forstå algoritmen for å utføre K-gjennomsnitt-klyngeanalyse og hierarkisk klyngeanalyse
- Forstå hvordan klyngeanalyse utføres i Python

Læringsressurser

Tema Klyngeanalyse:

- **Korte videoer**: (by Mette Langaas)
  - Klyngeanalyse (8:43 min)
  - Hierarkisk klyngeanalyse (11:26 min)
  - K-gjennomsnitt-klyngeanalyse (8:38 min)
- Denne forelesningen
- **Disse slides** med notater

Som alltid se her:

https://wiki.math.ntnu.no/istx100y/2026h/1003

Klyngeanalyse – hva er det?

Vi har data

$$X : n \times p$$

men *ikke* noen respons Y. *Ikke-veiledet = unsupervised*

Mål:

- Finn ukjente klynger i dataene.
- Observasjoner innen hver klynge er mer lik hverandre enn observasjoner fra ulike klynger.

Hva skal vi bruke resultatene fra klyngeanalysen til?

- Bildet: Fjerne støy eller, spare lagringsplass
- Medisin: Finne subgrupper av en sykdom $\rightarrow$ relevant for behandling?

Klyngeanalyse – hva er det?

Generelt: Finne *struktur* i dataene.

Kan vi stole på resultatene? Hvor robuste er de?

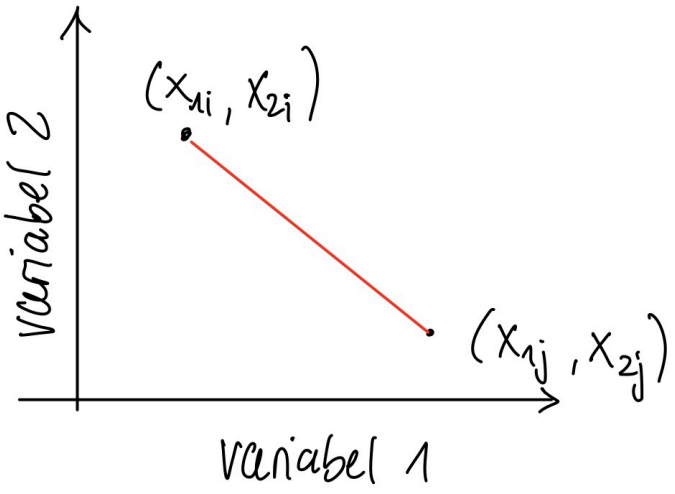
→ Fortsatt et forskningsområde!

Avstandsmål

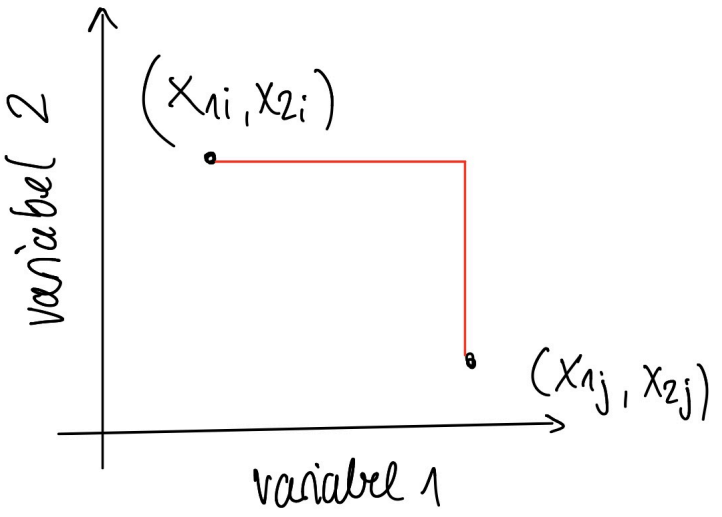
Før vi kan gjøre en klyngeanalyse, må vi først definere en *avstand* mellom to datapunkter.

To populære avstandsmal:

Euklidsk



City-block (=Manhattan)



Euklidsk **City-block (=Manhattan)**

$$D_E(i,i') = \sqrt{\sum_{j=1}^{p}(x_{ji} - x_{ji'})^2} \qquad D_M(i,i') = \sum_{j=1}^{p}|x_{ji} - x_{ji'}|$$

Avstandsmål i mer enn 2 dimensioner: Enkelt å regne, men litt vanskelig å forestille seg.

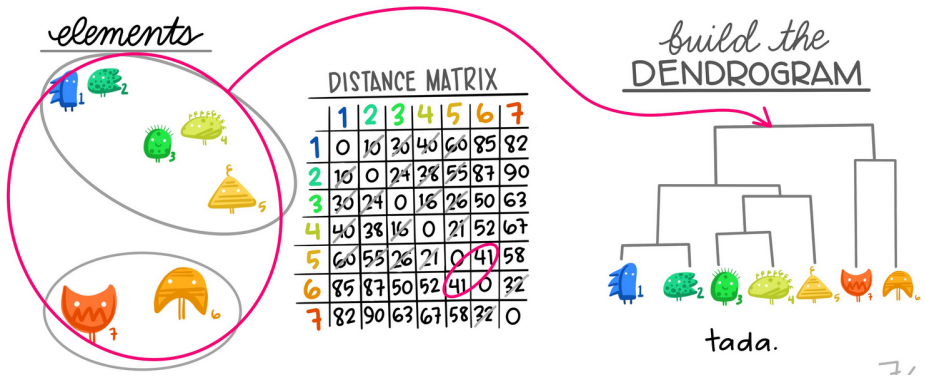
Metoder for klyngeanalyse

Det finnes ganske mange metoder, men vi ser på to som er (mest?) populær:

K-gjennomsnitt klyngeanalyse



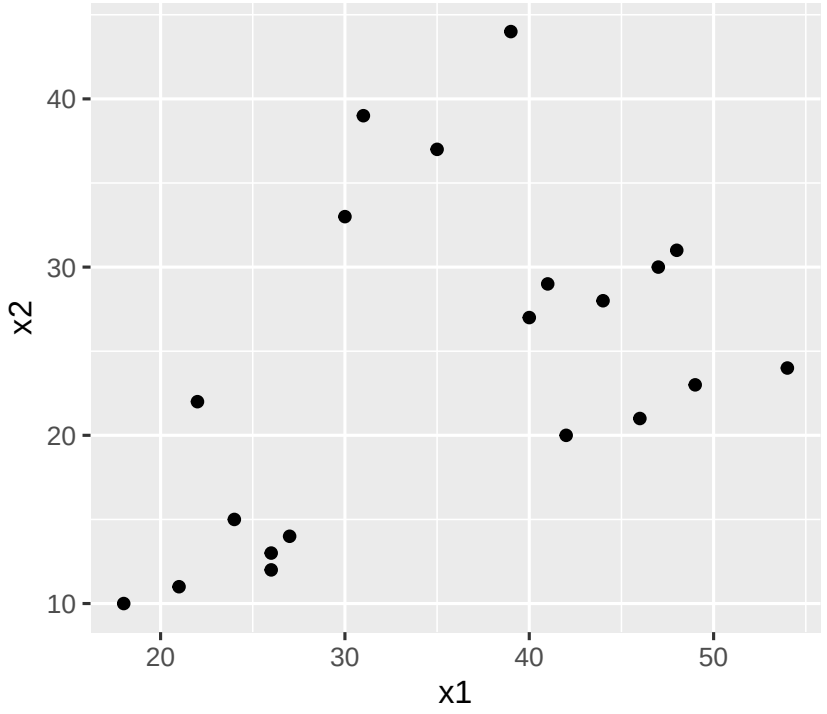
Hierarkisk klyngeanalyse



Artwork by @allison_horst

K-gjennomsnitt klyngeanalyse

- Finn K ukjente klynger i dataene.



- Alle observasjoner skal være medlem i akkurat *én* klynge.
- Variasjonen innen hver klynge skal være så liten som mulig.

Variasjon innen en klynge k

- K klynger $C_1, \ldots, C_k, \ldots, C_K$.
- Antall observasjoner i klynge k: $|C_k|$.
- Variasjon i klynge k:

$$\frac{1}{|C_k|} \sum_{i,i' \in C_k} \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2$$

Optimeringsproblem

Vi vil *minimere* variasjon over *alle klynger*:

$$\sum_{k=1}^{K} \frac{1}{|C_k|} \sum_{i,i' \in C_k} \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2$$

Nyttig sammenhang som er grunnlaget for k-gjennomsnittsalgoritme

$$\sum_{k=1}^{K} \frac{1}{|C_k|} \sum_{i,i' \in C_k} \sum_{j=1}^{p} (x_{ij} - x_{i'j})^2$$

$$= \sum_{k=1}^{K} 2 \sum_{i \in C_k} \sum_{j=1}^{p} (x_{ij} - \overline{x}_{kj})^2 \ ,$$

med *klyngesentroide* i klynge k: $\overline{x}_k = (\overline{x}_{k1}, \ldots, \overline{x}_{kp})$.

K-gjennomsnitt algoritme

- Start med å velge antall klynker K.
- Tilordne hver observasjon til en klynge
  - Mange muligheter
    - å tilfeldig velge ut K observasjoner og sette disse som klyngesentroider, og deretter tilordne de resterende observasjonene til klyngen med nærmeste klyngesentroide.
    - tilfeldig klynger
- Repeter (iterativt) *til ingen observasjoner endrer klyngemedlemskap*:
  1. For hver klynge regn ut klyngesentroiden
  2. Tilordne hver observasjon til klyngen til nærmeste klyngesentroide

Illustrasjon av K-gjennomsnitt algoritme ($K = 3$)

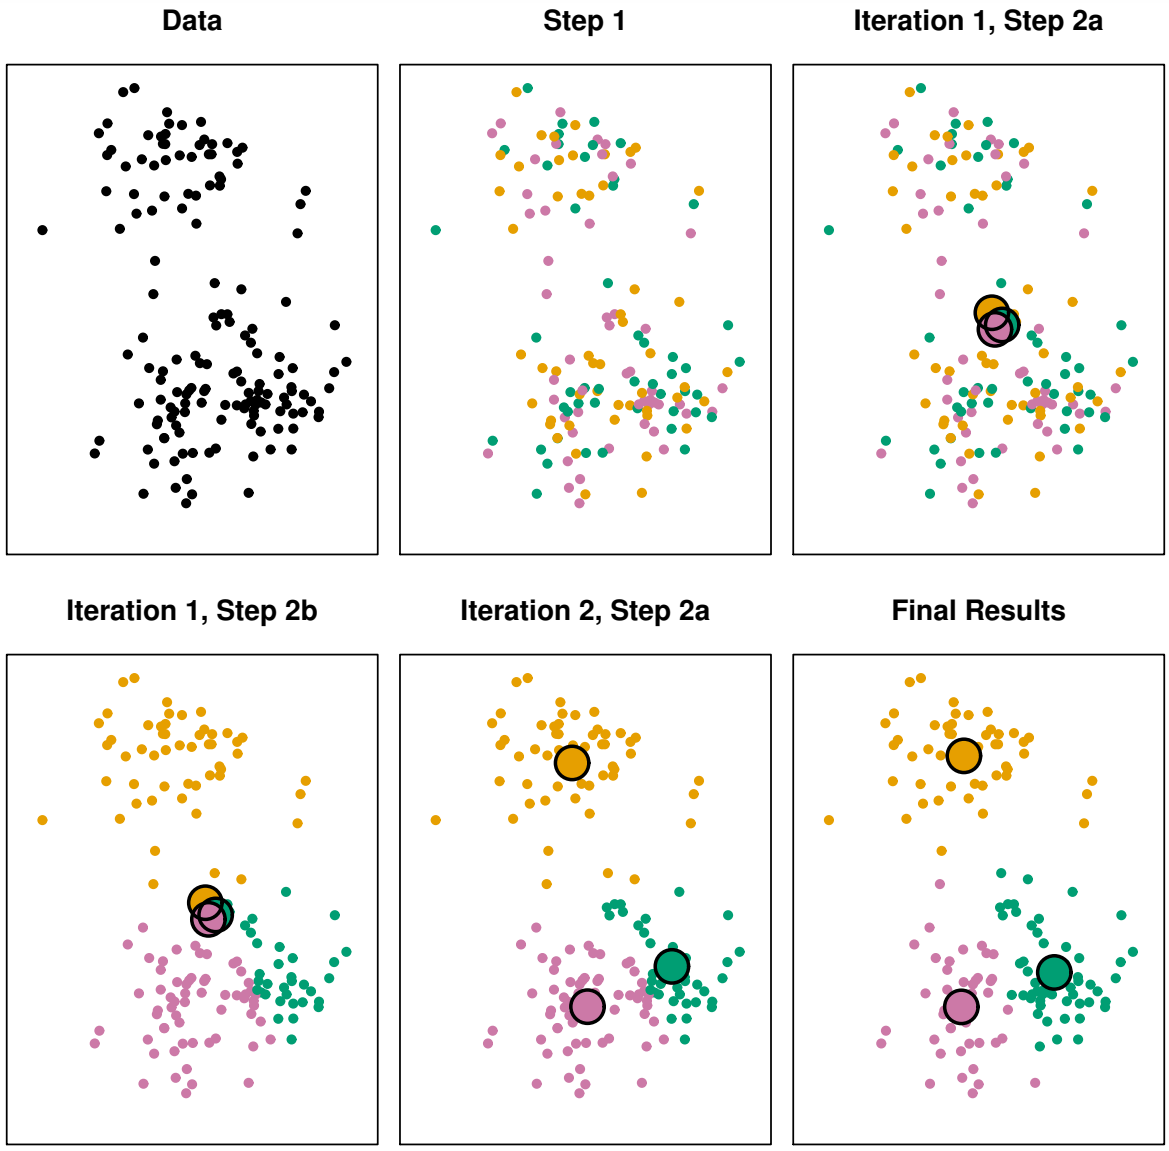


Fig. 10.6 fra "An Introduction to Statistical Learning with Applications in R", James et al 2013.

Python kodechunk kmeans (K-gjennomsnitt-algoritmen)

- Package:
```
from sklearn.cluster import KMeans
```

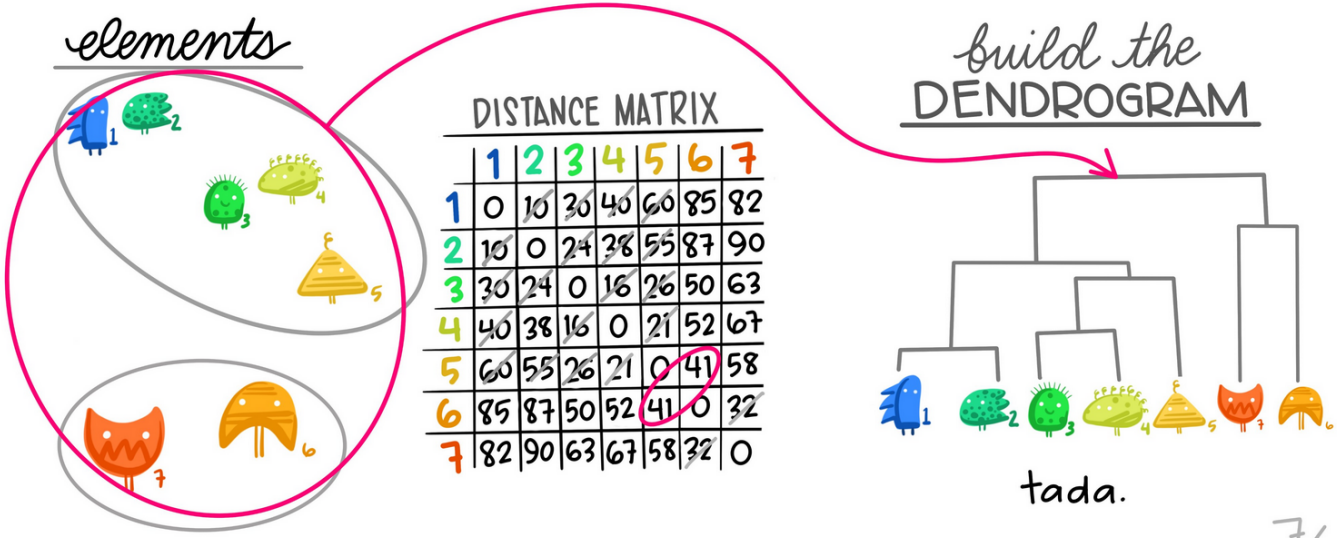
- Steg 1: Antall klynger
```
antall_klynger = 10
```

- Steg 2: Initaliser k-means algoritmen
```
kmeans = KMeans(n_clusters = antall_klynger,
random_state = 1)
```

- Steg 3: Tilpass modellen
```
kmeans.fit(images)
```

- Sentroidene
```
sentroider = kmeans.cluster_centers_
```

Hierarkisk klyngeanalyse



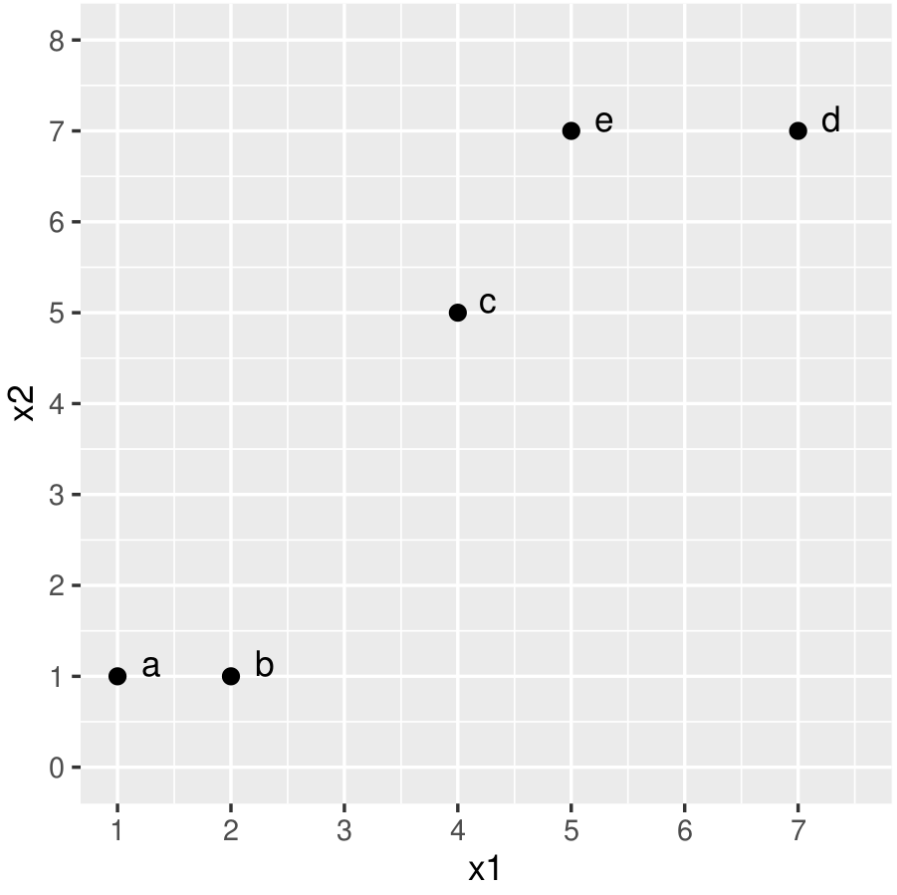
	1	2	3	4	5	6	7
1	0	10	30	40	60	85	82
2	10	0	24	38	55	87	90
3	30	24	0	16	26	50	63
4	40	38	16	0	21	52	67
5	60	55	26	21	0	41	58
6	85	87	50	52	41	0	32
7	82	90	63	67	58	32	0

Artwork by @allison_horst

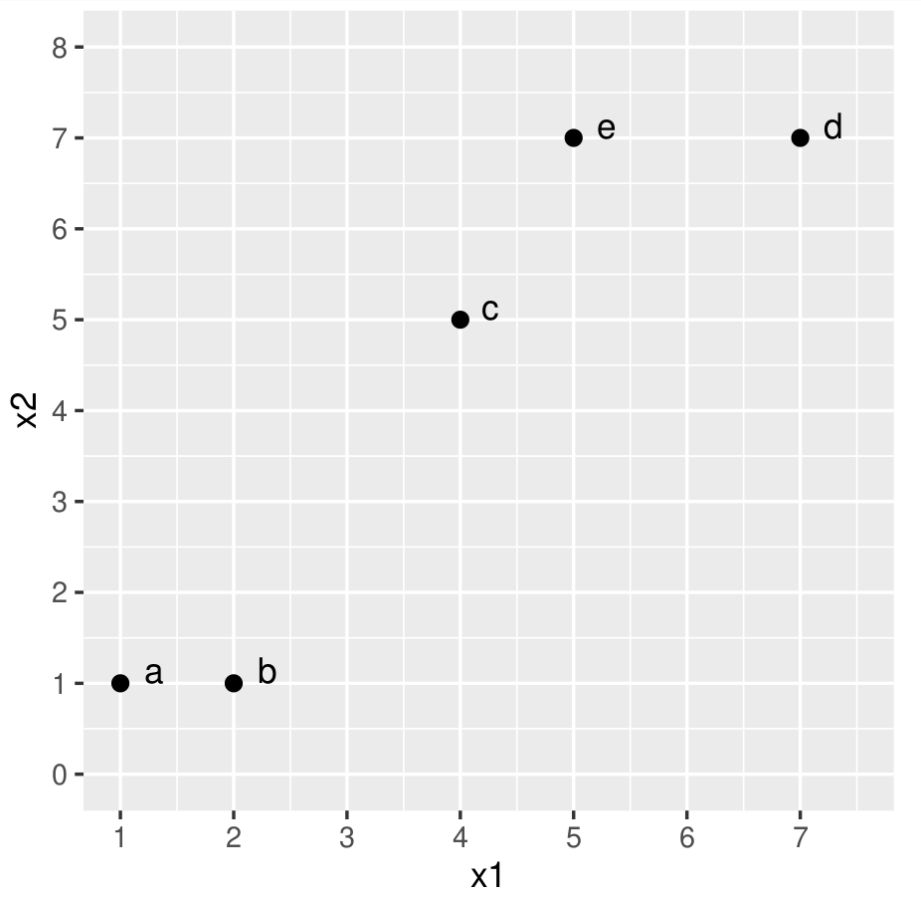
Eksempel

$n = 5, p = 2$

x1	x2	name
1	1	a
2	1	b
4	5	c
7	7	d
5	7	e

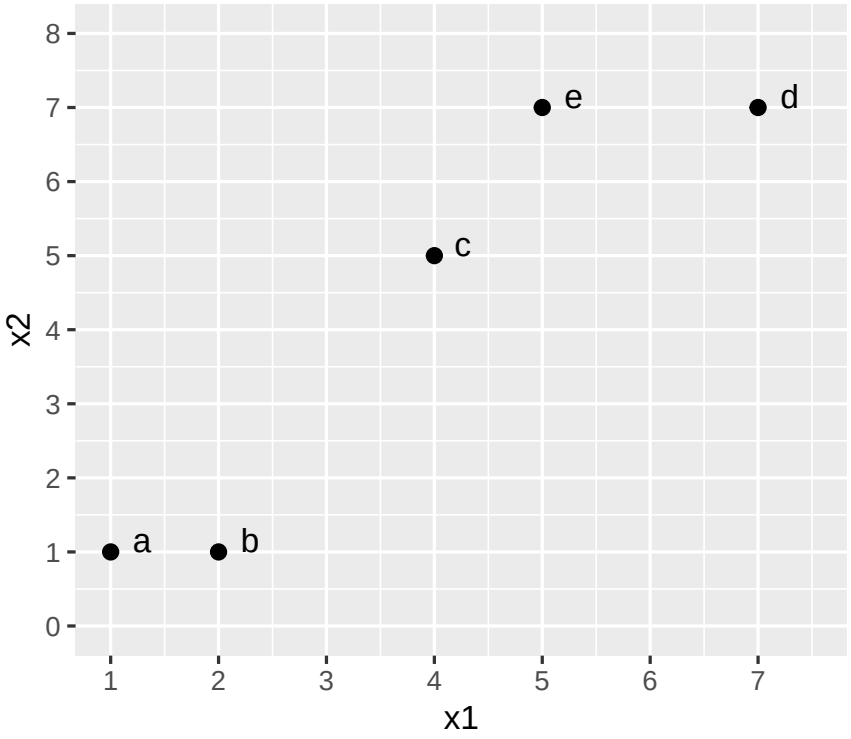


x1	x2	name
1	1	a
2	1	b
4	5	c
7	7	d
5	7	e



1) Velg avstandsmål.
2) Regn ut avstanden mellom alle par av observasjoner.
3) Plasser avstandene inn i en $n \times n$ matrise.

Avstandsmatrise (Euklidsk avstand)

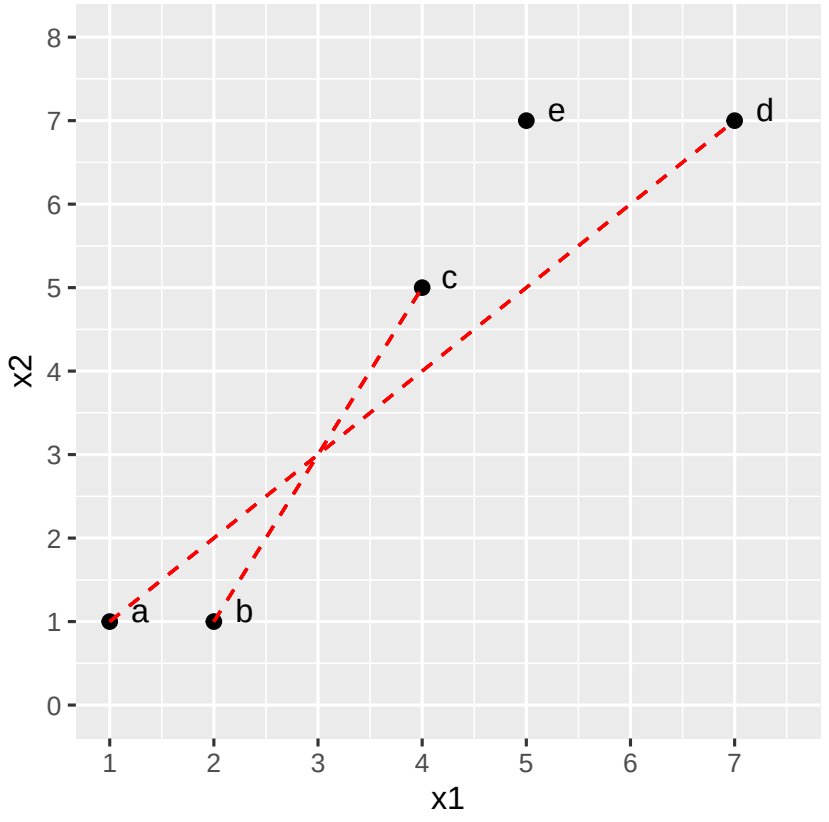


name	a	b	c	d	e
a	0.0	1.0	5.0	8.5	7.2
b	1.0	0.0	4.5	7.8	6.7
c	5.0	4.5	0.0	3.6	2.2
d	8.5	7.8	3.6	0.0	2.0
e	7.2	6.7	2.2	2.0	0.0

Avstand mellom klynger?

Tre populære typer avstandsmål:

- **Singel kobling**: minimal avstand
- **Komplett kobling**: maksimal avstand
- **Gjennomsnittskobling**: gjennomsnittlig avstand



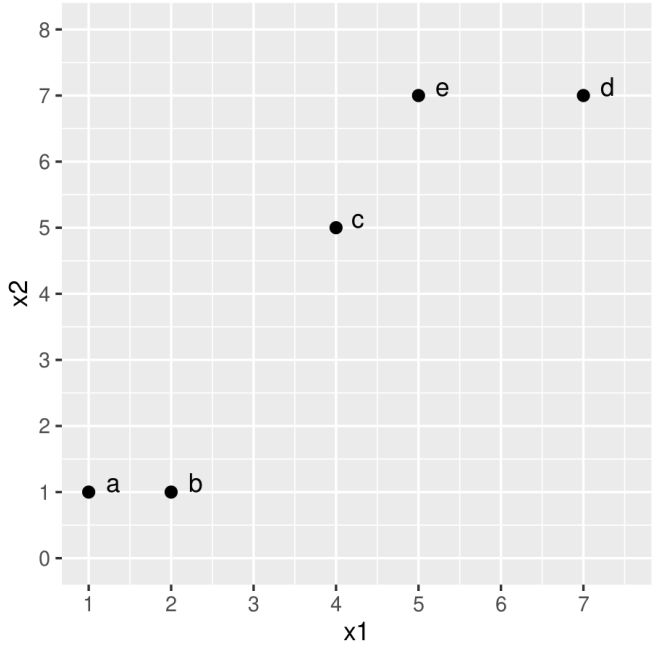
Algoritme for hierarkisk klyngeanalyse - I

Før algoritmen starter man bestemme seg for

- hvilket avstandsmål skal brukes (f.eks: euklidsk, city block, korrelasjon,...)
- hvilken koblingtype skal brukes (f.eks: singel, komplett, gjennomsnitt, sentroide,...)

og regne ut avstandsmatrisen mellom alle observasjoner.

name	a	b	c	d	e
a	0.0	1.0	5.0	8.5	7.2
b	1.0	0.0	4.5	7.8	6.7
c	5.0	4.5	0.0	3.6	2.2
d	8.5	7.8	3.6	0.0	2.0
e	7.2	6.7	2.2	2.0	0.0



Algoritme for hierarkisk klyngeanalyse – II

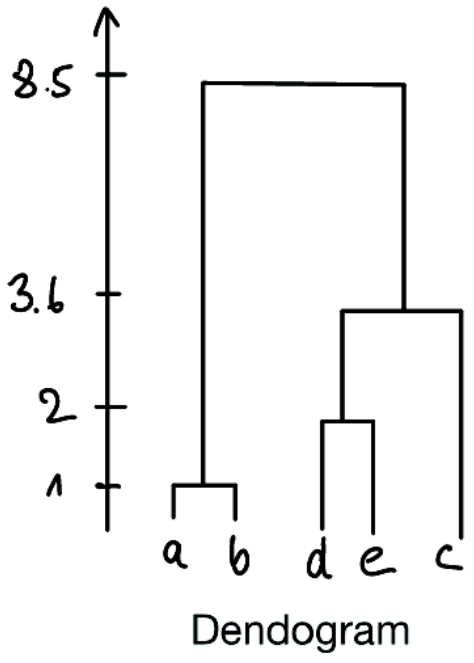
Behandle hver observasjon som om den var sin egen klynge (det er da n klynger).

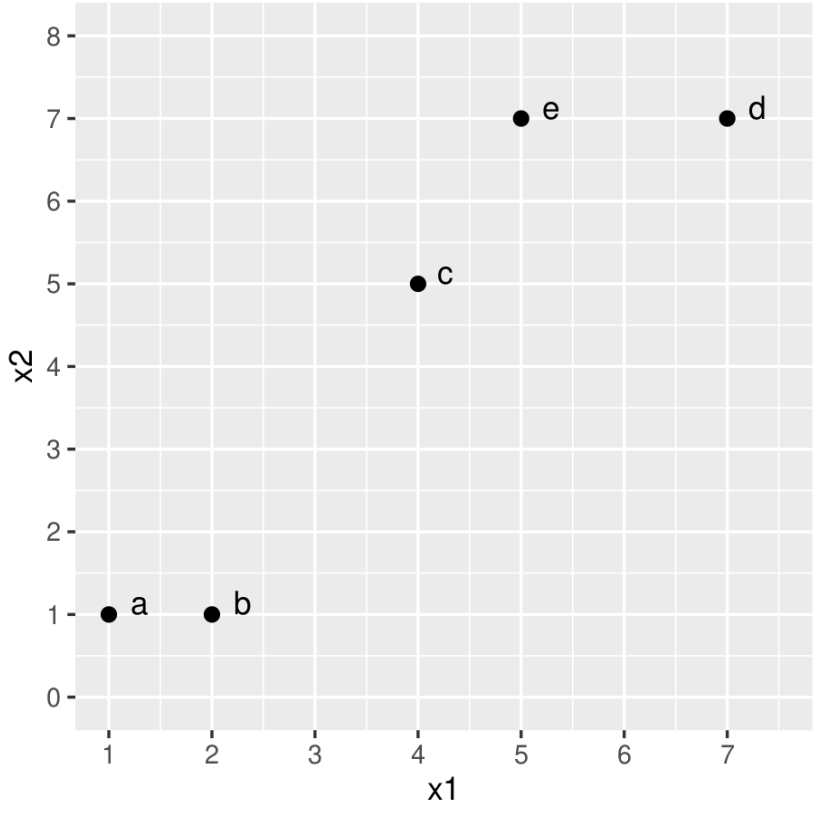
1. **Slå sammen**
   Finn de to klyngene som er nærmest hverandre og slå dem sammen til en klynge.
2. **Beregn avstander**
   Beregn nye parvise avstander mellom alle klynger ved bruk av valgt avstandsmål og koblingstype.

Repeterer til alle observasjonene er i samme klynge.

Resultat fra vår eksempel (dendogram)

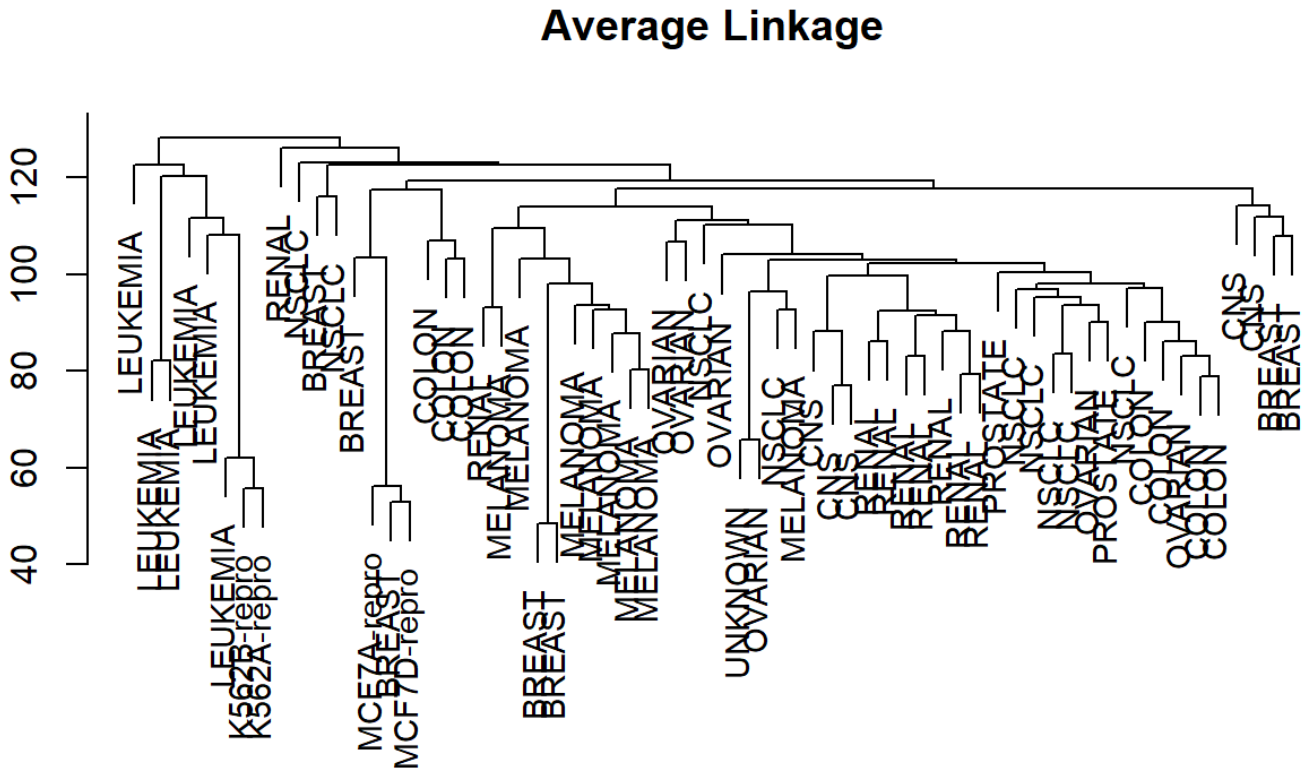
Ved bruk av komplett kobling (maksimal avstand):





Eksempel: Genaktivitet

- n=64 celleprøver fra kreftsvulster til ulike pasienter.
- genaktivitet for $p = 6830$ gener.



https://bookdown.org/aurora_tumminello/statistics_lab/nci60-data-example.html#clustering-the-nci60-observations

Videre de neste to ukene

- Hvis dere ikke har gjort det: Se på de korte videoene for hvert tema.
- Jobb med prosjektoppgaven. Husk at frist for innlevering av prosjektet til Inspera er **mandag 16.november kl 12.00**.
- For informasjon om veiledning (fysisk og digital), se her: https://wiki.math.ntnu.no/istx100y/2026h/1003
- Husk også diskusjonsforumet på Canvas – det fungerer best for korte spørsmål.