

Klyngeanalyse

ISTx1003 Statistisk læring og Data Science

Stefanie Muff, Institutt for matematiske fag

Oktober 28, 2025



Oppgave 3

Anerkjennelse

Disse slides bygger på slides fra Mette Langaas, 2020.

Takk til Mette for at jeg fikk bruke noen av materialene.

Plan for i dag (tema “Klyngeanalyse”)

- Hva er klyngeanalyse?
- Læringsmål, pensum og læringsressurser
- Avstandsmål
- K-gjennomsnitt (“K-means”) klyngeanalyse
- Bruk av klyngeanalyse på et bilde (prosjektet fra i fjor)
- Hierarkisk klyngeanalyse
- Informasjon om prosjektet

Eksempel 1: Genaktivitet


↗ pasienter

- $n = \underline{81}$ celleprøver fra kreftsvulster til ulike pasienter
- Genaktivitet for $p = \underline{12957}$ gener

Spørsmål:

- Hvilke celleprøver fra brystkreftpasienter ligner hverandre mest?
- Kan vi finne ukjente klynger (av celleprøver) i dataene?

Dette kan hjelpe for å forutsi sannsynligheten for en tilbakefall.




$$X = p \times n = \text{gener} \times \text{prøver} .$$

Finn ut mer: <https://cgp.iiarjournals.org/content/8/4/199>

Eksempel 2: Proteininteraksjonsnettverk

Kan vi finne klynger med relatert funksjon?

MUFF, RAO, AND CAFLISCH



PHYSICAL REVIEW E 72, 056107 (2005)


FIG. 4. (Color online) (a) Largest connected component of the PPI of *E. coli*. The colors represent the clusterization found by optimizing modularity. (b) *LQ* clusterization of the black *Q* cluster. The green circle contains proteins belonging to the DNA polymerase complex. The unknown protein b1808 is assigned to this complex according to *LQ* while the complete *Q* cluster is heterogeneous.

Eksempel 3: Bildanalyse


Mål:

Å bruke klyngeanalyse til å fjerne detaljer og støy - ved å dele pikslene inn i to eller flere klynger.

Hver piksel har en farge som er definert som en blandig av rød, grønn og blå (x, y, z) :



$$\# \text{ piksler } 400 \cdot 600 = 24'000$$



Klyngeanalyse: Finn k “typiske farger” som representerer klynger (sentroider) og erstatt hver piksel med sentroidfargen.

Jeg var litt nysgjerrig...

Opprinnelig bilde



Jeg var litt nysgjerrig...

Opprinnelig bilde



Bilde i svart/hvitt



Jeg var litt nysgjerrig...

Opprinnelig bilde



Bilde i svart/hvitt



bilde med 8 klynger



Læringsmål

- Forstå hvorfor det er interessant å gjøre klyngeanalyse
- Kjenne igjen situasjoner der klyngeanalyse vil være en aktuell metode å bruke
- Kjenne begrepene avstandsmål, koblingstype, dendrogram
- Forstå algoritmen for å utføre K-gjennomsnitt-klyngeanalyse og hierarkisk klyngeanalyse
- Forstå hvordan klyngeanalyse utføres i Python
- Kunne besvare problem 3 av prosjektoppgaven på en god måte!

Læringsressurser

Tema Klyngeanalyse:

- **Korte videoer:** (by Mette Langaas)
 - Klyngeanalyse (8:43 min)
 - Hierarkisk klyngeanalyse (11:26 min)
 - K-gjennomsnitt-klyngeanalyse (8:38 min)
- Denne forelesningen
- **Disse slides** med notater

Som alltid se her:

<https://wiki.math.ntnu.no/istx100y/2025h/1003>

Klyngeanalyse – hva er det?

Vi har data

observasjoner
(parallell
pixler)
 $X : n \times p$
variabler
(farger
gener...)

men ikke noen respons Y . *Ikke-veiledet = unsupervised*

Mål:

- Finn ukjente klynger i dataene.
- Observasjoner innen hver klynge er mer lik hverandre enn observasjoner fra ulike klynger.

Hva skal vi bruke resultatene fra klyngeanalysen til?

- Bildet: Fjerne støy eller, spare lagringsplass
- Medisin: Finne subgrupper av en sykdom → relevant for behandling?

Klyngeanalyse – hva er det?

Generelt: Finne *struktur* i dataene.

Kan vi stole på resultatene? Hvor robuste er de?


→ Fortsatt et forskningsområde!

Avstandsmål


Før vi kan gjøre en klyngeanalyse, må vi først definere en *avstand* mellom to datapunkter.

To populære avstandsmål:

Euklidsk




City-block (=Manhattan)



↓

Euklidsk *# variable* City-block (=Manhattan)


$$D_E(i, i') = \sqrt{\sum_{j=1}^p (x_{ji} - x_{ji'})^2} \qquad D_M(i, i') = \sum_{j=1}^p \underbrace{|x_{ji} - x_{ji'}|}$$


Avstandsmål i mer enn 2 dimensioner: Enkelt å regne, men litt vanskelig å forestille seg.

Metoder for klyngeanalyse


Det finnes ganske mange metoder, men vi ser på to som er (mest?) populære:

K-gjennomsnitt klyngeanalyse



En enkel metode


Hierarkisk klyngeanalyse



Veldig populær!

K-gjennomsnitt klyngeanalyse

- Finn K ukjente klynger i dataene.



- Alle observasjoner skal være medlem i akkurat én klynge.
- Variasjonen innen hver klynge skal være så liten som mulig.

Variasjon innen en klynge k

- K klynger $C_1, \dots, C_k, \dots, C_K$.

- Antall observasjoner i klynge k : $|C_k|$.
- Variasjon i klynge k :

C_1, C_2, C_3 sett av obs.

For en klynge k

$$\frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

kvadrert avstand i, i'

Optimeringsproblem

Vi vil *minimere* variasjon over *alle* klynger:

$$\sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2$$

summen over alle K klynger

$n=100, K=3$
 $3^{100} \approx 5 \cdot 10^{45}$
muligheter å danne klynger!



[K er fiks!]

Nyttig sammenhang som er grunnlaget for k -gjennomsnittsalgoritme

Vi vil minimere det: $\left\{ \sum_{k=1}^K \frac{1}{|C_k|} \sum_{i, i' \in C_k} \sum_{j=1}^p (x_{ij} - x_{i'j})^2 \right.$

$$= \sum_{k=1}^K 2 \sum_{i \in C_k} \sum_{j=1}^p (x_{ij} - \bar{x}_{kj})^2,$$

med *klynge*sentroide i klynge k : $\bar{x}_k = (\bar{x}_{k1}, \dots, \bar{x}_{kp})$.



K-gjennomsnitt algoritme

- • Start med å velge antall klynger K .
- Tilordne hver observasjon til en klynge
 - Mange muligheter
 - å tilfeldig velge ut K observasjoner og sette disse som klyngesentroider, og deretter tilordne de resterende observasjonene til klyngen med nærmeste klyngesentroide.
 - tilfeldig klynger
- **Repeter** (iterativt) *til ingen observasjoner endrer klyngemedlemskap*:
 1. For hver klynge regn ut klyngesentroiden
 2. Tilordne hver observasjon til klyngen til nærmeste klyngesentroide

Illustrasjon av K -gjennomsnitt algoritme ($K = 3$)




Fig. 10.6 fra "An Introduction to Statistical Learning with Applications in R", James et al 2013.

Python kodechunk kmeans (*K*-gjennomsnitt-algoritmen)

- Package:

```
from sklearn.cluster import KMeans
```

- Steg 1: Antall klynger

```
antall_klynger = 10
```

- Steg 2: Initialiser k-means algoritmen

```
kmeans = KMeans(n_clusters = antall_klynger,  
random_state = 1)
```

→ seed (tilfeldig startkonfig.)

- Steg 3: Tilpass modellen

```
kmeans.fit(images)
```

data


- Sentroidene

```
sentroider = kmeans.cluster_centers_
```


Prosjektoppgaven

Vi kan se sammen på prosjektoppgaven.

Hierarkisk klyngeanalyse



Artwork by @allison_horst


Truget ikke å bestemme K på forhånd!

Eksempel


$$n = 5, p = 2$$

x1	x2	name
1	1	a
2	1	b
4	5	c
7	7	d
5	7	e

data




x1	x2	name
1	1	a
2	1	b
4	5	c
7	7	d
5	7	e



- 1) Velg avstandsmål. *→ velges Euklidisk*
- 2) Regn ut avstanden mellom alle par av observasjoner.
- 3) Plasser avstandene inn i en $n \times n$ matrise.

Avstandsmatrise (Euklidsk avstand)




name	a	b	c	d	e
a	0.0	1.0	5.0	8.5	7.2
b	1.0	0.0	4.5	7.8	6.7
c	5.0	4.5	0.0	3.6	2.2
d	8.5	7.8	3.6	0.0	2.0
e	7.2	6.7	2.2	2.0	0.0

$$\frac{5 \cdot 4}{2} = 10 \text{ avstander}$$

Avstand mellom klynger?

Tre populære typer avstandsmål:

- **Singel kobling:** minimal avstand
- **Komplett kobling:** maksimal avstand
- **Gjennomsnittskobling:** gjennomsnittlig avstand




Algoritme for hierarkisk klyngeanalyse - I

Før algoritmen starter man bestemme seg for

- hvilket avstandsmål skal brukes (f.eks: euklidsk, city block, korrelasjon,...)
- hvilken koblingstype skal brukes (f.eks: singel, komplett, gjennomsnitt, sentroide,...)

og regne ut avstandsmatrisen mellom alle observasjoner.

name	a	b	c	d	e
a	0.0	1.0	5.0	8.5	7.2
b	1.0	0.0	4.5	7.8	6.7
c	5.0	4.5	0.0	3.6	2.2
d	8.5	7.8	3.6	0.0	2.0
e	7.2	6.7	2.2	2.0	0.0



Algoritme for hierarkisk klyngeanalyse – II

Behandle hver observasjon som om den var sin egen klynge (det er da n klynger).

1. Slå sammen

Finn de to klyngene som er nærmest hverandre og slå dem sammen til en klynge.



2. Beregn avstander

Beregn nye parvise avstander mellom alle klynger ved bruk av valgt avstandsmål og koblingstype.

Repeterer til alle observasjonene er i samme klynge.

Resultat fra vår eksempel (dendrogram)


Ved bruk av komplett kobling (maksimal avstand):



ab
c
d
e

Eksempel: Genaktivitet

- $n=64$ celleprøver fra kreftsvulster til ulike pasienter.
- genaktivitet for $p = 6830$ gener.



Prosjektoppgaven 3

- Hva er hovedforskjellene mellom K-gjennomsnitt-klyngeanalyse og hierarkisk klyngeanalyse?
- Hva er parameteren/parametrene på K-gjennomsnitt? På hierarkisk klyngeanalyse?
- Hvorfor har vi ikke brukt trenings-, validerings- og testsett her?

Videre de neste to ukene

- Hvis dere ikke har gjort det: Se på de korte videoene for hvert tema.
- Jobb med prosjektoppgaven. Husk at frist for innlevering av prosjektet til Inspira er **mandag 17.november kl 12.00**.
- Vi har digital veiledning via Whereby (www.whereby.com) begge uker for Ålesund og Gjøvik. Se her:
<https://wiki.math.ntnu.no/istx100y/2025h/1003>
- Husk også **mattelab** forumet – det fungerer best for korte spørsmål.